

Một vài ghi chép về Toán cho sinh viên ngành AI

Bùi Văn Vượng

Kì xuân 2025

1 Độc lập xác suất

Khái niệm độc lập: Hai sự kiện có thể là độc lập một cách không hề trực quan. Ví dụ, một số x được chọn ngẫu nhiên từ $\{1, 2, 3, 4\}$. Hai sự kiện chúng ta quan tâm là $A = x \in \{1, 2\}$ và $B = x \in \{1, 3\}$ có vẻ như không độc lập, vì nếu sự kiện B xảy ra, chúng ta có một quan điểm thay đổi về khả năng của A xảy ra. Lý do là nếu B xảy ra thì có khả năng nhất định $x = 1$ thứ mà cũng có nghĩa A xảy ra. Nói theo một cách khác $P(A|B)$ có vẻ đã khác $P(A)$ lúc đầu. Tuy nhiên, ở đây có một sự trùng hợp thú vị. Hai xác suất A, B là như nhau với $P(A) = P(B) = \frac{1}{2}$, và xác suất A, B xảy ra đồng thời là $P(x = 1) = \frac{1}{4}$. Như vậy $P(A \wedge B) = P(A)P(B)$. Lưu ý rằng sự trùng hợp này phụ thuộc rất nhiều vào kích thước của sample space. Nếu như tập này không có chính xác 4 số thì sự phụ thuộc đã không còn là độc lập. Thật vậy, nếu tập sample space là $\{1, 2, 3, 4, 5\}$ thì các xác suất tương ứng là $P(A) = P(B) = \frac{2}{5}$ nhưng $P(A \wedge B) = P(x = 1) = \frac{1}{5}$ và điều kiện $P(A \wedge B) = P(A)P(B)$ không còn được thoả mãn.

Về mặt toán học, sự kiện A độc lập với sự kiện B nếu như $P(A|B) = P(A)$, tức là điều kiện B xảy ra sẽ không ảnh hưởng gì tới xác suất A xảy ra. Lưu ý về tính đối xứng hay thứ tự ở đây không quan trọng vì $P(A|B) = P(A)$ sẽ kéo theo $P(B|A) = P(B)$. Đúng vậy,

$$\begin{aligned} P(A \wedge B) &= P(A|B)P(B) = P(B|A)P(A) \\ \implies P(B|A)/P(B) &= P(A|B)/P(A) = 1. \end{aligned}$$

Thực ra, điều kiện $P(A \wedge B) = P(A)P(B)$ cũng thường xuyên được dùng để định nghĩa tính độc lập của 2 sự kiện A, B .

Bài tập 1. Chứng minh rằng nếu A, B độc lập thì các cặp sự kiện sau cũng độc lập: $(A, \neg B)$, $(\neg A, B)$, $(\neg A, \neg B)$.

Bài tập 2. Giả định không gian mẫu là rời rạc hữu hạn, A, B là các sự kiện được biểu diễn bởi một tập con với kích thước $|A| = x, |B| = y, |A \cap B| = z$. Hãy đặt kích thước không gian mẫu theo x, y, z sao cho các sự kiện A, B là độc lập.

Trong trường hợp đặc biệt $A \subseteq B$, nếu như biết A xảy ra thì chắc chắn B sẽ xảy ra. Khi này, A, B sẽ thường không độc lập với nhau và thường thì $P(B|A) > P(B)$.

Bài tập 3. Tuy nhiên, ở đây vẫn có trường hợp A, B độc lập. Đó là gì?

Một vài sự kiện thì lại độc lập theo hướng rất trực quan. Ví dụ, lấy một số ngẫu nhiên x từ tập $\mathbb{N}$. Hai sự kiện A: x là số nguyên dương chia hết cho 2 và B: x là số nguyên dương chia hết cho 5 là độc lập vì

$$P(A) = \frac{1}{2}, P(B) = \frac{1}{5}, P(A \wedge B) = \frac{1}{10}.$$

Trực quan là vì ở đây nếu một số biết là chia hết cho 5 thì ta cũng không có biết thêm gì về việc nó có chia hết cho 2 hay không.

Tuy nhiên, ví dụ này vẫn rất phụ thuộc vào tập lấy mẫu. Giả sử tập đó được mở rộng thành tập số nguyên $\mathbb{Z}$. Khi đó,

$$P(A) = \frac{1}{2}, P(B) = \frac{1}{5}, P(A \wedge B) = \frac{1}{10}.$$

làm cho A, B không còn là hai biến cố độc lập.

Nói một cách khác, chúng ta chỉ cần giữ nguyên 2 sự kiện độc lập và mở rộng tập lấy mẫu thì ngay lập tức chúng trở thành không độc lập. Điều đó có nghĩa là tính độc lập hay tính phụ thuộc có thể rất mơ hồ. Nói cụ thể hơn, đôi khi chúng ta không thật quan tâm hai sự kiện bản chất có độc lập hay không mà chúng ta chỉ quan tâm tính chất toán học của chúng, rằng liệu chúng ta có thể viết $P(A \wedge B) = P(A)P(B)$ trong các công thức. Trực giác là công cụ nhưng công thức mới là kết quả chúng ta cần.

Ở chiều hướng ngược lại, khi không gian mẫu quá lớn, chúng ta có thể thu gọn không gian mẫu lại để hai sự kiện trở lên độc lập. Ví dụ: nếu x lấy từ tập mẫu $\mathbb{N}$ và hai sự kiện là A: x chia hết cho 4 và x chia hết cho 6 thì hai sự kiện này không độc lập. Tuy nhiên nếu ta đặt không gian mẫu Ω là các số tự nhiên chia hết cho 2 thì hai sự kiện A, B lại trở nên độc lập. Khái niệm tương ứng cho hiện tượng này gọi là “conditional independence”: A, B được gọi là độc lập với điều kiện C nếu với điều kiện cho trước C xảy ra thì A, B độc lập, hay chính xác hơn là

$$P(A \wedge B|C) = P(A|C)P(B|C).$$

Cụ thể với C là sự kiện x chia hết cho 2 thì

$$P(A|C) = \frac{1}{2}, P(B|C) = \frac{1}{3}, P(A \wedge B|C) = \frac{1}{6},$$

trong đó sự kiện $A \wedge B$ là x chia hết cho 12.

Bài tập 4. Cho hai số a, b bất kì, x được lấy ngẫu nhiên từ $\mathbb{N}$. Nếu A là sự kiện x chia hết cho a và B là sự kiện x chia hết cho b , thì A, B độc lập với điều kiện nào?

Một điều may mắn là, trong thực tế, khi chúng ta nói hai sự kiện X, Y độc lập, chúng ta thường gặp hai sự kiện này được lấy mẫu trong hai thế giới “song song”. Ví dụ: sự kiện X là số x được lấy từ một tập S nào đấy và chia hết cho 2 và sự kiện Y là số y được lấy từ một tập T nào đấy và chia hết cho 5. Khi này chúng ta không hề ràng buộc gì về không gian mẫu, cụ thể là S, T tùy ý. Tập mẫu của chúng ta sẽ là $(x, y) \in S \times T$ và hiển nhiên

$$P(x \in X \wedge y \in Y) = \frac{|X||Y|}{|S||T|} = \frac{|X|}{|S|} \cdot \frac{|Y|}{|T|} = P(x \in X)P(y \in Y).$$

Một khái niệm cũng liên quan thường gặp là i.i.d. random variables (i.i.d viết tắt identical independent distributed). Cụ thể $X_1, \dots, X_n$ được i.i.d. theo một phân phối X nếu như chúng được lấy từ các không gian mẫu song song như trên. (Vấn đề này sẽ được nhắc lại sau.)

Chúng ta tạm bỏ qua các không gian song song và quay lại trường hợp tổng quát. Khi có nhiều hơn hai sự kiện ngẫu nhiên thì mọi thứ có thể phức tạp hơn khi bàn về independence.

Bài tập 5. Hãy tìm ví dụ về 3 sự kiện E_1, E_2, E_3 sao cho mọi cặp E_i, E_j đều độc lập nhưng

$$P(E_1 \wedge E_2 \wedge E_3) \neq P(E_1)P(E_2)P(E_3).$$

Chúng ta có khái niệm “mutual independent”: Các sự kiện $E_1, \dots, E_n$ được gọi là mutual independent nếu với mọi tập con $I \subseteq \{1, \dots, n\}$, chúng ta có

$$P\left(\bigcap_{i \in I} E_i\right) = \prod_{i \in I} P(E_i).$$

Khái niệm này hoàn toàn khác “pairwise independent”: tất cả các cặp E_i, E_j độc lập. Cụ thể thì “mutual independence” là một điều kiện mạnh hơn.

Bài tập 6. Cho các số $a_1, \dots, a_n$ nào đấy và số x được lấy ngẫu nhiên từ $\mathbb{N}$. Các sự kiện $(E_i)_{i=1, \dots, n}$ được định nghĩa là số x chia hết cho a_i . Nếu như $E_1, \dots, E_n$ là mutual independent, thì ta có thể nói gì về $a_1, \dots, a_n$? Ở đây, mutual independence có khác gì pairwise independence không?

Mutual independence có thể được phát biểu thông qua khái niệm độc lập giữa hai sự kiện thông thường: Mỗi sự kiện E_i sẽ độc lập với giao của một tập con bất kì của $\{E_1, \dots, E_n\} \setminus \{E_i\}$.

Bài tập 7. Chứng minh hai định nghĩa của “mutual independence” là tương đương nhau.

Bài tập 8. Đưa ra ví dụ để chỉ ra rằng điều kiện

$$P(E_1 \wedge \dots \wedge E_n) = P(E_1) \dots P(E_n)$$

là không đủ mạnh để suy ra được rằng $E_1, \dots, E_n$ là mutual independent với nhau.

Chúng ta quan tâm điều kiện mutual independence vì chúng ta cần chứng minh kết quả sau đây:

$$P(\neg E_1 \wedge \neg E_2 \wedge \dots \wedge \neg E_n) = P(\neg E_1) \dots P(\neg E_n).$$

Bài tập 9. Hãy chứng minh điều trên và đồng thời chứng minh luôn $\neg E_1, \dots, \neg E_n$ là mutual independent. (Gợi ý: dùng inclusion–exclusion principle; tìm hiểu thật kỹ về nguyên lý này, hết sức quan trọng!)

Công thức trên khá quan trọng: Giả sử E_i là những sự kiện tệ mà chúng ta không mong muốn và chúng ta không muốn bất cứ sự kiện tệ nào xảy ra. Chúng ta cũng biết rằng các sự kiện tệ này không là tất yếu, tức $P(E_i) < 1$. Nếu như các sự kiện này mutual independent thì chúng ta kết luận được rằng có một xác suất dương nào đấy, dù nhỏ, rằng không có sự kiện xấu nào xảy ra.

Rất nhiều các bài toán ngôn ngữ của chúng là tổ hợp với các thành phần rời rạc và chúng ta phải chứng minh rằng một cấu hình nào đấy tồn tại. Một cách thú vị là ta có thể biến chúng thành ngôn ngữ của xác suất và chứng minh rằng xác suất của một sự kiện nào đấy là dương (khác không). Tên gọi của kỹ thuật này là “probabilistic method”. (Sẽ được giới thiệu sau!)

Những biến ngẫu nhiên độc lập

Hai biến ngẫu nhiên X, Y được gọi là độc lập nếu hai sự kiện $X = x$ và $Y = y$ là độc lập với mọi x, y . Khi này định nghĩa về mutual independence

có thể được phát biểu đơn giản hơn so với trường hợp của các biến cố: Các biến ngẫu nhiên $X_1, X_2, \dots, X_n$ được gọi là độc lập cùng nhau nếu

$$P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \dots P(X_n = x_n)$$

với mọi $x_1, \dots, x_n$.

Bài tập 10. Chứng minh rằng nếu $X_1, \dots, X_n$ độc lập cùng nhau thì $X_1, \dots, X_m$ cũng độc lập cùng nhau với mọi $m \leq n$.

1.1 Case study với Naive Bayes

Phân bố xác suất của một biến ngẫu nhiên X nào đó trong thực tế thường không được cho trước. Thay vào đó, các giá trị $x_1, \dots, x_m$ sẽ được lấy mẫu từ X , và thông qua chúng ta phải ước lượng các tham số của phân bố ngẫu nhiên, thứ sẽ đại diện cho biến ngẫu nhiên đó. Ví dụ, với một biến ngẫu nhiên đồng xu thì tham số ngẫu nhiên là θ xác suất đồng xu mặt ngửa (tức là mean khi head, tail mang giá trị 1, 0). Hay như biến ngẫu nhiên normal thì ta phải ước lượng mean và variance.

Thông thường để có thể có một ước lượng đáng tin cậy thì ta cần một số mẫu đủ lớn. Vì các lý do chi phí, số lượng mẫu này thường không hạn chế. Vấn đề sẽ còn phức tạp hơn khi chúng ta phải ước lượng phân bố hội của nhiều biến ngẫu nhiên, ví dụ như $P(X, Y, Z, T)$. Lúc này số mẫu cần thiết sẽ phải tăng theo mũ 4 nếu như chúng ta không có bất kì thông tin gì về các mối tương quan giữa X, Y, Z, T . Ngược lại, nếu như chúng độc lập cùng nhau ta lại có

$$P(X, Y, Z, T) = P(X)P(Y)P(Z)P(T).$$

Lúc này với số mẫu nhỏ thì $P(X), P(Y), P(Z), P(T)$ cũng đã có được một ước lượng đủ tốt.

Ngoài những dạng bài với xác suất hội thì ta còn dạng bài phân loại rằng lớp C là gì với đầu vào cho trước gồm nhiều biến ngẫu nhiên $X_1, \dots, X_n$. Nói cách khác, chúng ta phải ước lượng

$$P(C|X_1, \dots, X_n),$$

và xác định giá trị $C = c$ sao cho xác suất trên đạt cực đại. Theo công thức Bayes, ta có thể viết lại thành

$$\frac{P(X_1, \dots, X_n|C).P(C)}{P(X_1, \dots, X_n)}.$$

Vì xác suất cho mọi giá trị $C = c$ đều có chung mẫu, ta chỉ quan tâm tới tử số. Thành phần $P(C)$ có thể dễ dàng ước lượng. Tuy nhiên, thành phần

$P(X_1, \dots, X_n|C)$ cần một điều kiện độc lập có điều kiện của $X_1, \dots, X_n$ với điều kiện C để có thể biểu diễn thành

$$P(X_1|C) \dots P(X_n|C).$$

Lúc này mọi thành phần đều có thể dễ dàng ước lượng.

Câu hỏi đặt ra là tại sao lại là độc lập có điều kiện mà không chỉ đơn thuần là các biến $X_1, \dots, X_n$ độc lập cùng nhau? Ví dụ, liệu X_1, X_2 có độc lập với nhau? Ta viết

$$P(X_2|X_1) = \sum_c P(C|X_1)P(X_2|C, X_1) = \sum_c P(C|X_1)P(X_2|C),$$

thứ mà thông thường sẽ khác

$$\sum_c P(C)P(X_2|C) = P(X_2),$$

vì C và X_1 không độc lập với nhau nên làm cho $P(C)$ có thể khác $P(C|X_1)$.

Ngược lại, nếu như dữ kiện ban đầu chỉ cho là $X_1, \dots, X_n$ độc lập với nhau thì ta sẽ phải viết

$$P(X_1, \dots, X_n|C) = \frac{P(X_1, \dots, X_n, C)}{P(C)} = \frac{P(X_1, \dots, X_n).P(C|X_1, \dots, X_n)}{P(C)}$$

và dù cho ta có viết tiếp được $P(X_1, \dots, X_n) = P(X_1) \dots P(X_n)$ thì cũng không giúp ích được gì nhiều vì ta quay lại bài toán ngay ban đầu với $P(C|X_1, \dots, X_n)$. Hay nói một cách khác, việc biết phân bố của đầu vào $X_1, \dots, X_n$ không có tác dụng gì nhiều trong ước lượng đầu ra C .

2 Giá trị kì vọng và các thông số thống kê liên quan

2.1 Nhiều hơn là kỳ vọng

Giá trị kì vọng, hay expectation, hay mean là một giá trị đại diện cho một dãy số hay một biến ngẫu nhiên. Khi nói về dãy số $x_1, \dots, x_n$ thì đó là

$$\frac{x_1 + \dots + x_n}{n}$$

còn khi nói về một biến ngẫu nhiên X thì đó là

$$\sum_x xP(X = x).$$

Câu hỏi đặt ra là tại sao lại quan tâm về giá trị kì vọng mà không phải một giá trị đặc trưng nào khác. Ví dụ, trung bình trên là trung bình cộng, tại sao lại không quan tâm trung bình nhân

$$\sqrt[n]{x_1 \dots x_n}?$$

Thông thường trong sách, giá trị kì vọng μ được dùng vì nó tối giản hoá hàm

$$\sum_{i=1}^n (x_i - \mu)^2.$$

Hay nói cách khác đây là giá trị tối giản hoá tổng các bình phương khoảng cách (least square estimator).

Bài tập 11. Chứng minh điều này! Đồng thời hãy viết và chứng minh cho trường hợp biến ngẫu nhiên X .

Tuy nhiên, chúng ta hãy nghĩ tới những bài toán thực tế hơn, nơi mà bình phương khoảng cách nghe khá khiên cưỡng. Ví dụ: chúng ta sống trong toà nhà 100 tầng mà số lượng người sống ở mỗi tầng là $x_1, \dots, x_{100}$. Thời gian đi từ tầng i tới tầng j sẽ tỉ lệ với với khoảng cách chúng, cho như là $|i - j|$ giây. Khi này chúng ta cần đặt phòng họp chung ở một tầng z mà tối thiểu hóa tổng thời gian đi lại

$$\sum_{i=1}^n x_i |i - z|.$$

Bài tập 12. Hãy tìm z .

Không khó để nhận ra đáp án là giá trị z “nằm giữa” theo nghĩa: nếu S là tổng số người $\sum_{i=1}^n x_i$ thì một nửa số người nằm dưới z và một nửa số người nằm trên z , hay chính xác hơn là

$$\sum_{i=1}^z x_i \geq \frac{S}{2}, \sum_{i=z}^n x_i \geq \frac{S}{2}.$$

Với các giá trị x_i cho trước thì dường như giá trị z này không phải là một thống kê quen thuộc. Tuy nhiên, chúng ta hãy thay đổi phát biểu: Chúng ta có S người ở tại các tầng $y_1, \dots, y_S$, khi này tổng thời gian đi lại là

$$\sum_{i=1}^S |y_i - z|.$$

Giá trị z thoả mãn khi này là “median” của dãy số $y_1, \dots, y_S$ theo nghĩa nếu như dãy này được sắp xếp tăng dần thì giá trị z nằm đâu đó tại $y_{S/2}$ (tùy thuộc tính chẵn lẻ của S).

Bài tập 13. Kiểm định lại điều này!

Như vậy, bản chất là chúng ta đã thay đổi hàm tối ưu từ tổng các bình phương thành tổng các giá trị tuyệt đối. Không khó để nhận ra rằng tổng các giá trị tuyệt đối sẽ có nghĩa hơn trong thực tế. Ví dụ: chi phí nên tỉ lệ với đường đi hơn là tỉ lệ với bình phương đường đi. Tuy nhiên, điều này cũng có nghĩa là chúng ta phải luôn bám với thực tế. Ví dụ: với một vài người thì leo cầu thang sức lực bỏ ra sẽ là mũ 4 của đường đi. Bài tập: Hãy tìm giá trị z tối thiểu hoá

$$\sum_{i=1}^n (x_i - z)^4$$

với một dãy $x_1, \dots, x_n$ nào đó.

Tại sao hàm tổng bình phương lại được sử dụng nhiều như thế, không chỉ trong giới hạn của bài toán này mà đa phần trong thế giới học máy. Một trong những nguyên nhân là tính toán học đẹp của nó, chúng ta dễ dàng thao tác với chúng hơn là trị tuyệt đối: chúng ta tách thoải mái và lấy đạo hàm đơn giản hơn. Bản chất chúng ta không nhất thiết phải mô hình hoá lỗi bằng chính xác hàm lỗi thực tế mà chỉ cần một hàm lỗi nào đó tăng đồng điệu cùng. Hãy lưu ý tính chính xác và tính dễ tính là hai đại lượng thường phải đánh đổi cho nhau.

Tuy nhiên, chúng ta vẫn cần phải đại lượng hóa những sai lệch có thể xảy ra thay vì phớt lờ chúng. Cụ thể, ta định nghĩa median cho một biến ngẫu nhiên X là giá trị m sao cho

$$P(X \leq m) \geq \frac{1}{2}, P(X \geq m) \geq \frac{1}{2}.$$

Chúng ta có thể chặn trên sự khác biệt giữa kì vọng μ và median m của một biến ngẫu nhiên X bằng một đại lượng thống kê khác của X :

$$|\mu - m| = |E(X - m)| \leq E(|X - m|) \leq E(|X - \mu|) \leq \sqrt{E((X - \mu)^2)} = \sigma.$$

Bài tập 14. Giải thích từng bước trong biến đổi!

Ở đây σ là độ lệch chuẩn của X , là căn bậc hai của phương sai

$$D(X) = E((X - E(X))^2).$$

Cả hai đều cho chúng ta ý niệm về sự tập trung của dữ liệu quanh giá trị trung bình.

Bài tập 15. Điều gì xảy ra khi $D(X) = 0$. Variance của một biến có thể là vô hạn không? Nếu có vô hạn thì hãy đưa ví dụ. Liệu khoảng cách giữa μ và m có thể vô hạn không?

Ngoài bất đẳng thức Cauchy phổ biến thì trong phép biến đổi có bước sử dụng Jensen's inequality rằng với một hàm lồi ϕ thì

$$\phi(E(X)) \leq E(\phi(X)).$$

Bất đẳng thức này sẽ thường xuyên được sử dụng và ở đây hàm ϕ là hàm trị tuyệt đối.

Bài tập 16. Kiểm tra định nghĩa hàm lồi và chứng minh hàm trị tuyệt đối là lồi.

Ngoài mean, median, còn đại lượng thống kê mode, được định nghĩa là giá trị phổ biến nhất trong một dãy số cho trước.

Bài tập 17. Hãy tìm hàm lồi mà mode sẽ tối thiểu hóa hàm đó. Phát biểu và chứng minh cho cả trường hợp dãy số và biến ngẫu nhiên. Hãy tìm một ví dụ thực tế cho những hàm lồi như vậy.

2.2 Consistent estimator (đang xây dựng)

Cho một dãy các biến ngẫu nhiên $X_1, \dots, X_n$ i.i.d. với X uniform trên $[0, 1]$.

Bài tập 18. Chứng minh rằng khoảng cách δ_n giữa trung bình cộng của $X_1, \dots, X_n$ và median của $X_1, \dots, X_n$ sẽ tiến tới 0 theo nghĩa: Với mọi $\epsilon > 0$ thì $P(\delta_n > \epsilon)$ hội tụ tới 0 khi $n \rightarrow \infty$. (Khái niệm này còn được gọi là converges in probability.)

Bài tập 19. Median của $X_1, \dots, X_n$ có tiến tới median của X không? (Lưu ý là trước là biến ngẫu nhiên còn sau là số.)

Bài tập 20. Nếu X không phải là uniform trên $[0, 1]$ thì median của $X_1, \dots, X_n$ có tiến tới mean của X không?

Kết quả rằng trung bình cộng của $X_1, \dots, X_n$ tiến tới mean của X là một kết quả quan trọng của xác suất (và sẽ được đề cập sau).

Phần này hơi nâng cao, bỏ cũng được.

3 Ước lượng tham số

Mỗi phân bố xác suất hay chính xác hơn là một họ phân bố xác suất sẽ được đặc trưng bởi một hoặc nhiều tham số nào đấy. Ví dụ phân bố Bernouli được đại diện bởi tham số θ với $P(\text{Head}) = \theta$. Nếu như Head là 1 và Tail

là 0 thì θ cũng là mean. (Nếu Tail là -1 thì sao?) Như phân bố chuẩn thì được đại diện bởi hai tham số tương ứng là mean và variance.

Thông thường nếu như nói một biến ngẫu nhiên X phân bố Bernouli có thể hiểu là X có một tham số θ nào đó. Tương tự như việc một đồng xu nhất định sẽ có những đặc tính vật lý sẽ quyết định khả năng mặt ngửa là bao nhiêu. Tuy nhiên, ta thường không được tiếp cận đo đạc đồng xu này mà chỉ được lấy các kết quả tung thử đồng xu. Giả định chúng ta đã tung 100 lần và ra 51 ngửa và 49 xấp, khi này ta có thể tạm tính là $\theta = .51$. Tuy nhiên, nếu như chúng ta tung 3 lần và cả 3 lần đều ra ngửa thì chúng ta có được “tạm tính” là $\theta = 1$ không? Có lẽ ta sẽ kết luận như thế và kết luận thêm rằng kết luận này không có độ tin cậy cao như kết luận trước với $\theta = .51$. Nhưng như nào là một kết luận đáng tin cậy?

Chúng ta sẽ xem xét nó trước góc nhìn Bayesian. Có một thứ chắc chắn ở đây là có một giá trị θ unique nào đó mà biến ngẫu nhiên X mang. Tuy nhiên, chúng ta không hề biết nên việc tốt nhất có thể làm là coi θ như một biến ngẫu nhiên và cũng gán xác suất cho những sự kiện $\theta = \theta_0$. Khi này, phân bố chúng ta quan tâm lại là

$$P(\theta|x_1, \dots, x_m),$$

trong đó $x_1, \dots, x_m$ là kết quả lấy mẫu m lần từ biến ngẫu nhiên X . Chúng ta thấy có bóng dáng Naive Bayes ở đây. Ngay từ ban đầu, chúng ta cho rằng các kết quả $X_1, \dots, X_m$ sẽ lấy i.i.d. theo cùng phân bố X theo nghĩa chúng độc lập với nhau. Hay nói cách đơn giản hơn là kết quả tung từng đồng xu là không liên quan gì tới nhau. Tuy nhiên, ta cũng có thể nói là chúng độc lập điều kiện, với điều kiện ở đây là θ . Khi θ đã được xác lập thì các biến sẽ được lấy mẫu độc lập riêng rẽ. Cụ thể, ta sẽ viết

$$P(\theta|x_1, \dots, x_m) = \frac{P(x_1, \dots, x_m|\theta)P(\theta)}{P(x_1, \dots, x_m)}. \quad (1)$$

Ở đây mẫu cũng sẽ ít được quan tâm vì giống nhau. Nếu như bài toán là tìm θ để cực đại hoá xác suất thì ta chỉ quan tâm tử. Thông thường chúng ta sẽ giả định ban đầu là các θ có khả năng như nhau. Tức là, ta chỉ cần cực đại hoá $P(x_1, \dots, x_m|\theta)$. Xác suất này gọi là likelihood của $x_1, \dots, x_m$. Vì tính độc lập có điều kiện được cho trước, ta viết tiếp

$$P(x_1, \dots, x_m|\theta) = P(x_1|\theta) \dots P(x_m|\theta) = \theta^\ell (1 - \theta)^{m-\ell},$$

trong đó ℓ là số lần kết quả là head. Việc tìm θ cực đại hoá $P(x_1, \dots, x_m|\theta)$ được gọi là ước lượng maximum likelihood, và đại lượng $P(x_1, \dots, x_m|\theta)$ được gọi là likelihood.

Bài tập 21. Chứng minh rằng likelihood đạt cực đại khi $\theta = \frac{\ell}{m}$.

Như vậy dù số mẫu m lớn hay m nhỏ thì việc chia số lần head cho m vẫn sẽ cho ra giá trị θ khả dĩ nhất. Tuy nhiên, lưu ý rằng giá trị cực đại ở đây giống như mode, nó chưa bao giờ thật sự đại diện cho một phân bố (thậm chí mean, mode, median, variance gộp lại cũng không bao giờ đủ). Chúng ta có thể tưởng tượng khi vẽ đồ thị $P(\theta|x_1, \dots, x_m)$ trên khoảng $\theta \in [0, 1]$, đồ thị sẽ co cụm hơn tại giá trị $\frac{\ell}{m}$ khi m lớn, và ngược lại. Hay nói cách khác, khi m nhỏ, xác suất θ xa $\frac{\ell}{m}$ lại không phải không đáng kể.

Bài tập 22. Hãy thử nhập các phân bố này trên máy tính để vẽ biểu đồ trong một vài trường hợp.

3.1 Xác suất tiên nghiệm và cực đại posterior

Chúng ta đã giả định rằng $P(\theta)$ trong (1) là uniform. Điều đó có nghĩa là θ cực đại hóa posterior $P(\theta|x_1, \dots, x_m)$ sẽ chỉ được quyết định bởi $P(x_1, \dots, x_m|\theta)$. Tuy nhiên, trong thực tế, chúng ta thường ưu tiên những giá trị nhất định của tham số θ hơn các giá trị khác. Ví dụ trong trường hợp biến Bernoulli của đồng xu, ta ưu tiên các giá trị gần 0.5 hơn là các giá trị gần 0 và 1. Việc chọn một phân bố khác uniform cho xác suất prior này sẽ giải quyết vấn đề overfitting, khi mô hình học được phụ thuộc quá nhiều vào dữ liệu huấn luyện. Ví dụ: khi tung đồng xu 2 lần đều Head và chúng ta chọn $\theta = 1$ như là tham số cực đại likelihood. Tuy nhiên, lúc này nếu xác suất tiên nghiệm $P(\theta = 1)$ rất nhỏ sẽ cân bằng lại $P(\text{Head}, \text{Head}|\theta = 1)$ trong cực đại posterior.

Bài tập 23. Giả sử $P(\theta) \sim \theta^{20}(1-\theta)^{20}$, tính θ cực đại hóa posterior khi chúng ta tung đồng xu 2 lần và đều Head.

Chúng ta có thể thấy Prior probability trong bài tập trên lại chính là posterior probability khi chúng ta bắt đầu với Prior probability là uniform và quan sát thấy có 20 lần Head và 20 lần Tail. Ở đây có thể thấy tương quan số thí nghiệm mới không đáng kể so với số thí nghiệm cũ nên sẽ không làm thay đổi niềm tin trước đó. Ở khía cạnh ngược lại, chúng ta có thể nhìn nhận cả quá trình thực ra là tung đồng xu 42 lần.

Chúng ta thường dùng xác suất tiên nghiệm có dạng là xác suất hậu nghiệm vì những lí do như trên, hoặc cũng một phần vì khả năng dễ tính.

Bài tập 24. Thử một vài phân bố xác suất tiên nghiệm khác nhau và tính xác suất hậu nghiệm. Hãy so sánh dạng của xác suất tiên nghiệm và hậu nghiệm!

4 Entropy với ước lượng tham số

4.1 Entropy

Một biến ngẫu nhiên X có thể không được coi là ngẫu nhiên nếu như $P(X = 3) = 1.0$, nói cách khác X luôn luôn là 3. Thêm nữa, một biến ngẫu nhiên có thể theo một cách tương đối ít ngẫu nhiên hơn một biến ngẫu nhiên khác. Ví dụ: X sẽ bớt ngẫu nhiên hơn Y với $P(X = 3) = .5, P(X = 50000) = .5$ và $P(Y = 1) = P(Y = 2) = P(Y = 3) = \frac{1}{3}$. Thông kê cổ điển cũng có những đại lượng đại diện cho độ ngẫu nhiên này ở một mức độ nào đó. Ví dụ, phương sai cho chúng ta ý niệm về liệu dữ liệu có thật tập trung ở quanh trung bình không. Phương sai càng lớn thì dữ liệu thường rải rác. Tuy nhiên, lưu ý rằng trung bình hay phương sai là những đại lượng liên quan tới độ lớn của số. Ví dụ, biến ngẫu nhiên X ở trên sẽ có phương sai rất lớn so với Y , cho dù ta biết X chỉ là 1 trong 2 lựa chọn giá trị nào đấy. Vì thế, chúng ta cần một đại lượng thể hiện tính ngẫu nhiên của một phân bố rời rạc nào đấy mà không quan tâm tới giá trị của nó mà chỉ xác suất tại mỗi giá trị đấy. Cụ thể, chúng ta dùng entropy $H(X)$ của một biến ngẫu nhiên X , thứ được định nghĩa

$$H(X) = - \sum_x p(x) \log p(x).$$

Vấn tắt hơn, chúng ta có thể viết

$$H(X) = E(-\log p(X)).$$

4.2 Ý nghĩa của entropy

Ý nghĩa của entropy là đo sự ngẫu nhiên của biến ngẫu nhiên. Intuition của nó khá dài. Có thể đọc thêm ở Science and Information Theory của Léon Brillouin.¹

Nói một cách nôm na, nếu như chúng ta cần viết ra một dãy các giá trị $x_1, \dots, x_n$ mà mỗi x_i được sample i.i.d. từ cùng X thì chúng ta có thể encode biểu diễn chuỗi trên với xấp xỉ $n \cdot H(X)$ bits. Các bạn có thể đọc thêm phần này với Huffman coding. Phần này cũng đã trình bày phần này trên lớp.

Chúng ta cũng có một cách diễn tả tương đồng như sau. Giả sử chúng ta sample một số x từ biến ngẫu nhiên rời rạc X . Mỗi lần chúng ta được hỏi một câu hỏi Có/Không để tìm ra x . Ví dụ: x lớn hơn 5 hay không? hay x có thuộc tập $\{1, 5, 3\}$ không? Khi này, entropy của X “có thể” đại diện cho số lượng trung bình câu hỏi cần hỏi để tìm ra x . Lưu ý ta nói “có thể” ở

¹Mình mới xem qua thôi nhưng thấy ổn. Cuốn kinh điển thì là Elements of Information Theory, nhưng mà cuốn kiểu từ điển này đọc cũng không hiệu quả ngay lúc đầu!))

đây là vì nó chỉ đúng trong một vài trường hợp đẹp, còn ngoài ra chỉ là cận dưới của trung bình số lượng câu hỏi. Ví dụ: nếu X nhận hai giá trị A, B với $P(X = A) = 0.7$ và $P(X = B) = 0.3$ thì số lượng câu hỏi trung bình lớn hơn entropy, vì hiển nhiên chúng ta cần hỏi ít nhất 1 câu trong khi entropy lại nhỏ hơn 1.

Bài tập 25. Giả sử chúng ta sample i.i.d. 100 số $x_1, \dots, x_{100}$ số từ biên X nêu trên. Hãy đưa ra chiến lược hỏi để trung bình chúng ta cần ít hơn 100 câu hỏi! Liệu khi số câu hỏi n lớn hơn nhiều so với 100 thì chúng ta có tiệm cận $n \cdot H(X)$ hay không?

4.3 Relative entropy

Công thức tính entropy trên không dùng được cho các phân bố liên tục. Trong đa phần các trường hợp, ví dụ encoding, chúng ta không thật sự quan tâm về những phân bố này, ví dụ làm thế nào để encode một số thực bất kì trong máy tính (hãy nhớ lại vấn đề rằng các số thực là không đếm được với lập luận đường chéo của Cantor).

Dù không tính được entropy của những phân bố liên tục, chúng ta vẫn muốn so sánh tương đối sự khác nhau của hai phân bố. Có một định nghĩa về relative entropy cho hai biến ngẫu nhiên rời rạc p, q là

$$\sum_x p(x) \log \frac{p(x)}{q(x)}.$$

Chúng ta có thể viết lại thành

$$\left(- \sum_x p(x) \log q(x) \right) - \left(- \sum_x p(x) \log p(x) \right).$$

Đại lượng sau chính là entropy của p . Đại lượng trước gần như là entropy của p nhưng hơi khác chút. Nếu như $H(p)$ là số bit trung bình để encode mỗi phần tử sample từ p , thì đại lượng trước là số bit trung bình khi ta “tưởng” biến được sample từ q nhưng thực ra lại là sample từ p . Như chúng ta có thể phỏng đoán, cách này kém hiệu quả hơn, và vì thế đại lượng trước sẽ luôn lớn hơn $H(p)$ và relative entropy sẽ là không âm.

Bài tập 26. Chứng minh rằng nghiệm của bài toán tối thiểu hóa theo giá trị $q(x)$ của

$$- \sum_x p(x) \log q(x)$$

là $q(x) = p(x)$.²

²Hint: Có một bất đẳng thức đã được nhắc tới, liệu có tác dụng ở đây?

Chúng ta có thể mở rộng relative entropy cho vùng liên tục

$$\int_x p(x) \log \frac{p(x)}{q(x)} dx.$$

Lưu ý là ý nghĩa trong trường hợp liên tục có thể không được tường minh như khi hữu hạn.

Bài tập 27. Đại lượng trên có luôn hữu hạn không?

4.4 Sự thay đổi độ ngẫu nhiên sau mỗi lần ước lượng hậu nghiệm

Trong bài toán ước lượng tham số, ngay lúc đầu chúng ta bắt đầu bằng phân bố uniform của tham số. Chúng ta có thể cảm thấy độ ngẫu nhiên khi này là cao nhất. Tuy nhiên sau mỗi lần cập nhật lại phân bố tham số hậu nghiệm thì độ ngẫu nhiên này giảm. Lúc này chúng ta có thể “tạm” sử dụng công thức relative entropy mở rộng cho vùng liên tục để so sánh độ sai khác trong sự ngẫu nhiên giữa hai phân bố. Lưu ý rằng chúng ta nói là “tạm” vì bản thân chúng ta cũng không có đại lượng hóa được sự ngẫu nhiên của một phân bố liên tục và ý nghĩa của relative entropy trong trường hợp này cũng chưa thật rõ ràng. Tuy nhiên, nếu như chúng ta giả sử ngay từ đầu là θ chỉ nhận hữu hạn các giá trị, lúc này mọi thứ trở rõ ràng hơn nhiều.

Bài tập 28. Nếu như round đầu phân bố là uniform và được phân bố hậu nghiệm đầu tiên, thì $p(x), q(x)$ sẽ ứng với phân bố nào?

Bài tập 29. Trong round đầu tiên, giá trị sampling là ngẫu nhiên hay sắp thì có ảnh hưởng gì tới relative entropy không?

Bài tập 30. Nếu chạy 2 rounds, relative entropy có khác biệt không khi 2 kết quả là HH, HT, TH, TT ?

Bài tập 31. Thử tính kết quả nếu chạy 3 rounds!

Như chúng ta thấy bản thân relative entropy cũng sẽ giảm dần theo mỗi lượt cập nhật hậu nghiệm. Có thể tạm nói nôm na là lần sample thứ 100 không còn ý nghĩa nhiều như lần sample thứ 10, và càng không thể so sánh với lần thứ 1.

Bài tập 32. Hãy tính độ giảm của entropy sau mỗi lượt cập nhật hậu nghiệm thứ n , nó có thể được xấp xỉ theo những hàm nào? Ít nhất thì hãy đưa ra những giả định? Khó quá thì giải bài toán với những phân phối rời rạc ít giá trị.

Vấn đề ở đây là các lượt sample ít khi là free. Vì thế khi sự ngẫu nhiên không biến động nhiều, hay nói cách khác đường cong phân bố gần như không sai khác thì chúng ta nên kết thúc sampling để cập nhật hậu nghiệm. Lúc này bài toán sẽ là dừng lại với n bao nhiêu khi biết chi phí sampling. Thực tế thì hàm chi phí sampling cũng không tuyến tính, khi sample nhiều lần sẽ được chi phí mỗi lần tốt hơn.

Bài tập 33. Giả sử chi phí mỗi lần sẽ rẻ dần, ví dụ, lần sample thứ n sẽ tốn $1/n$ chi phí (lưu ý tổng $1 + 1/2 + 1/3 + \dots$ diverges). Cho trước δ nào đó, hãy tính khi nào dừng lại nếu mong muốn là tỉ lệ relative entropy và chi phí $1/n$ tại bước n nhỏ hơn δ ?

5 Tham số và các bài toán quyết định

Ước lượng tham số chưa phải là mục tiêu cuối cùng. Kiến thức về tham số nên được sử dụng để giúp đưa ra quyết định phù hợp hơn.

Giả sử chúng ta biết trước một đồng xu có tham số θ nào đó. Lúc này chúng ta sẽ tham gia một trò chơi với rất nhiều vòng: Mỗi vòng chúng ta sẽ đặt một lượng tiền nhất định và đặt cược đồng xu Head/Tail. Nếu đoán đúng bạn sẽ mất được số tiền đó, và ngược lại sẽ mất số tiền đó nếu đoán sai. Để thuận tiện ta qui ước số tiền lúc đầu là 1. Giả sử $\theta \geq 0.5$ thì việc mỗi lần chơi ta đều chọn Head, thứ có xác suất ít nhất 50% không có gì đáng phải bàn cãi (và ngược lại, ta chọn Tail nếu $\theta < 0.5$). Để thuận tiện, chúng ta cũng sẽ qui ước là $\theta \geq 0.5$ và mỗi lần chúng ta đều đặt Head. Bài toán hay hơn là mỗi bước chúng ta phải quyết định đặt bao nhiêu tiền. Nếu như $\theta = .9$ (hay thậm chí $\theta = .99$) thì liệu chúng ta có nên dồn hết số tiền vào các lần chơi hay không?

5.1 Số lượt chơi hữu hạn

Bài tập 34. Nếu như chúng ta chỉ chơi một round duy nhất, thì chúng ta nên đặt bao nhiêu để tối ưu hóa kì vọng số tiền đạt được.

Lưu ý là sau mỗi lần chơi, tùy thuộc vào số tiền chúng ta đặt cược và kết quả tung đồng xu mà số tiền của chúng ta sẽ thay đổi. Vì thế, thay vì nói mỗi lần chúng ta chơi bao nhiêu tiền thì chúng ta nói mỗi lần chúng ta sẽ chơi bao nhiêu phần trăm số tiền hiện có. Lựa chọn của chúng ta khi này chỉ là một tham số $x \in [0, 1]$ cho mỗi lần chơi.

Bài tập 35. Nếu như chúng ta chơi một số lần n round cố định nào đó thì sao? Các tham số $x_1, \dots, x_n$ để tối ưu kì vọng số tiền sau cuối là gì? Hãy tạm thử giải bài này với $n = 2, 3$ hoặc 4.

Như chúng ta sẽ thấy, khi số lần chơi là cố định thì chiến lược chơi luôn là “all-in” với việc đặt $x_1 = \dots = x_n = 1$. Tuy nhiên, khi số lần chơi là không cố định thì việc luôn theo đuổi lối chơi với dãy số $x_1, x_2, \dots = 1, 1, \dots$ sẽ làm cho gần như chắc chắn rằng chúng ta sẽ “trắng tay” tại một thời điểm nào đó.

Bài tập 36. Hãy thử phát biểu định nghĩa trên theo hướng hình thức và chứng minh nó!

Chúng ta hãy phân tích kĩ hơn. Để cho đơn giản, ta sẽ giả định các chuỗi của chúng ta đồng nhất với mỗi x_i sẽ đều nhận một giá trị x nào đấy. Khi đấy, giá trị kì vọng của số tiền thu được là

$$\sum_{r_1, \dots, r_n} \theta^\ell (1 - \theta)^{n-\ell} (1 + x)^\ell (1 - x)^{n-\ell},$$

trong đó $r_1, \dots, r_n$ là các kết quả tung đồng xu khả dĩ, ℓ là số lần mặt ngửa trong đó. Giá trị $\theta^\ell (1 - \theta)^{n-\ell}$ là xác suất của $r_1, \dots, r_n$. Giá trị $(1 + x)^\ell (1 - x)^{n-\ell}$ là số tiền nhận được trong trường hợp $r_1, \dots, r_n$. Như vậy, công thức trên diễn tả kỳ vọng số tiền nhận được.

Giá trị trên có thể được viết lại thành

$$\prod_{i=1}^n \sum_{v \in \{Head, Tail\}} [p(r_i = v)(1 + \text{sign}(v = Head)x)],$$

trong đó $p(r_i = v)$ là θ nếu $v = Head$ (và là $1 - \theta$ nếu $v = Tail$). Hàm $\text{sign}(v = Head)$ trả về giá trị 1 nếu $v = Head$ và -1 nếu ngược lại.

Bài tập 37. Việc tổng tích bằng tích tổng đã được nhắc một lần trên lớp. Hãy chứng minh lại về việc tại sao có thể viết được lại thành như trên!

Như vậy, để tối ưu hóa tích trên, chúng ta chỉ cần tối ưu hóa từng nhân tử

$$\sum_{v \in \{Head, Tail\}} [p(r_i = v)(1 + \text{sign}(v = Head)x)].$$

Thành phần này lại chính là giá trị kì vọng số tiền nhận được sau khi chơi một round duy nhất, viết lại thành

$$p(Head)(1 + x) + p(Tail)(1 - x) = \theta(1 + x) + (1 - \theta)(1 - x).$$

Ta thấy nếu $2\theta \geq 1$ thì ta chọn x cực đại có thể, tức là $x = 1$ hay nói cách khác là “all-in”. Điều này nghe rất không hợp lí. Vậy lỗi lập luận xuất hiện ở bước nào?

5.2 Tốc độ tăng khi lượt chơi vô hạn

Chúng ta hãy thử triển khai công thức theo hướng khác. Với một n nào đấy, ta đặt ℓ là số lượt chơi thắng (và $n - \ell$ là số lượt chơi thua). Số tiền nhận được khi này là

$$(1+x)^\ell(1-x)^{n-\ell}.$$

Giả sử chúng ta không quan tâm tới một n cụ thể mà xem xét giá trị trên khi n tăng lên vô cùng để xem xét tốc độ tăng theo hàm mũ. Như chúng ta đã biết, khi đấy chúng ta cũng cần lấy căn bậc n của đại lượng này, tức là

$$\lim_{n \rightarrow \infty} \sqrt[n]{(1+x)^\ell(1-x)^{n-\ell}}.$$

Biến đổi sơ bộ sẽ được

$$\lim_{n \rightarrow \infty} (1+x)^{\frac{\ell}{n}}(1-x)^{\frac{n-\ell}{n}}.$$

Chúng ta đều biết

$$\lim_{n \rightarrow \infty} \frac{\ell}{n} = \theta, \quad \lim_{n \rightarrow \infty} \frac{n-\ell}{n} = 1-\theta.$$

Điều này dẫn tới đại lượng tốc độ tăng sẽ được viết thành

$$(1+x)^\theta(1-x)^{1-\theta}.$$

Bài tập 38. Hãy giải theo θ một giá trị của x sao cho tốc độ tăng là cực đại.

Lưu ý phần trước chúng tối ưu hóa trung bình (cộng) $\theta(1+x) + (1-\theta)(1-x)$, trong khi lúc này chúng ta lại tối ưu hóa trung bình nhân $(1+x)^\theta(1-x)^{1-\theta}$ (tức là thay thế nhân bằng mũ và cộng bằng nhân).

Bài tập 39. Chuyện gì đang thật xảy ra. Tại sao trong số lượt chơi hữu hạn ta lại theo đuổi giá trị kì vọng trên các kết quả nhưng tới phần này chúng ta lại lấy giá trị số lần thắng cụ thể ℓ và tính toán lấy giới hạn trên nó?

Tài liệu tham khảo của phần này là bài báo: Kelly, John L. "A new interpretation of information rate." The Bell System Technical Journal 35.4 (1956): 917-926.

Bài tập 40. Khi số lượt chơi là không cố định và chúng ta chơi với các tham số x_1, x_2 khác nhau thì với xác suất 1, một trong hai người chơi sẽ dẫn trước người chơi kia sau một số lượt chơi đầu nào đó. Làm thế nào để biết điều này khi nhìn vào giá trị x_1, x_2 ?

5.3 Khi θ là một phân bố

Phần này sẽ nâng cấp độ khó lên khi θ không còn là giá trị cố định cho trước mà chúng ta chỉ biết phân bố xác suất của θ . Nói cách khác thì phần trình bày về ước lượng tham số thông qua các thí nghiệm đã trở lên hữu dụng và ăn nhập hơn. Tất nhiên chúng ta vẫn dựa trên tinh thần không lấy một giá trị θ^* sao cho $p(\theta^*)$ cực đại mà sẽ quan tâm tới toàn bộ phân bố.

Ở cài đặt đơn giản, chúng ta sẽ giả sử có một phân bố sẵn nào đấy và đưa ra chiến lược dựa trên phân bố đó.

Bài tập 41. Giả sử phân bố của θ là $p(\theta_1) = p_1$ và $p(\theta_2) = p_2$ với các giá trị $\theta_1, \theta_2, p_1, p_2$ nào đó. Hãy đưa ra chiến lược chơi!

Khi phân bố phức tạp hơn, hoặc thậm chí không rời rạc mà liên tục thì mọi thứ sẽ trở nên khó hơn nhiều.

Bài tập 42. Hãy đưa ra một phân bố liên tục của θ (đủ đơn giản nhưng không được là uniform) và giải bài toán tương ứng!

Ở cài đặt phức tạp hơn, chúng ta sẽ phải vừa học tham số θ vừa chơi. Giải sử xác suất tiên nghiệm là uniform thì số tiền đặt lần đầu có lẽ là 0 vì chúng ta không có thông tin gì về phân bố. Ở các lần tiếp theo thì chúng ta cập nhật lại phân bố hậu nghiệm, chúng ta có thể đưa ra các số tiền đặt lớn hơn tương ứng. Có lẽ phương án này sẽ là hợp lí trong dài hạn.

Bài tập 43. Kiểm tra điều này!

Chuyện gì xảy ra nếu số lượt chơi là cố định. Liệu để tối ưu hóa kì vọng, chúng ta có được phép “all-in” như trong một vài trường hợp đã phân tích không?

Bài tập 44. Giải quyết với số vòng cố định! Hãy thử với $n = 2, 3, 4$.

6 Hàm lỗi dưới góc nhìn xác suất

Chúng ta thường phát biểu bài toán Machine learning dưới dạng cho trước một họ hàm đặc trưng bởi những tham số nào đấy và một tập dữ liệu. Vì có thể không có hàm số nào trong họ hàm miêu tả chính xác dữ liệu, nhiệm vụ chúng ta là tìm một hàm trong họ sao cho tối thiểu hoá sự sai khác với dữ liệu.

Ví dụ, cho một tập các điểm $(x_1, y_1), \dots, (x_n, y_n)$ trên mặt phẳng, hãy tìm đường $y = ax + b$ sao cho nó xấp xỉ tốt nhất quan hệ x, y của các điểm.

Nếu như hàm lỗi chúng ta chọn là tổng bình phương độ sai lệch theo trục y , thì bài toán trở thành tìm a, b để tối thiểu hoá

$$\sum_{i=1}^n (ax_i + b - y_i)^2.$$

Như đã phân tích ở các phần trước, bình phương sẽ được chọn thay vì các hàm khoảng cách khác vì tính toán học đẹp, e.g. dễ đạo hàm. Và tổng khoảng cách là một hàm tỉ lệ với sự sai khác. Tuy nhiên, ở đây một người sẽ hỏi: Tại sao lại lấy tổng mà không lấy tích

$$\prod_{i=1}^n (ax_i + b - y_i)^2.$$

Trên nguyên tắc thì ta có thể chọn một hàm lỗi tùy ý và chúng ta sẽ không “cần” được ai đó định nghĩa hàm lỗi như trên. Tuy nhiên, hàm lỗi dễ bị thiết kế kém làm ảnh hưởng hiệu năng hệ thống. Người làm machine learning chủ yếu lấy hàm lỗi là bình phương khoảng cách theo kinh nghiệm, cho dù cũng không thật rõ tại sao hay khi nào nó không còn hiệu quả nữa.

Chúng ta hãy nhìn bài toán dưới góc độ xác suất. Khi này chúng ta sẽ giả định có một chân lí là hàm $y = ax + b$ nào đấy mà a, b chúng ta không biết. Hàm này thật sự mô tả chính xác dữ liệu của chúng ta. Sự sai khác chẳng qua là vì dữ liệu (x_i, y_i) thu thập bị lỗi/nhiều. Cụ thể, nếu x_i là đầu vào và không nhiễu, thì y_i thu thập được lại có nhiễu và giá trị thật y_i^* nên là một phân bố nào đấy với tham số y_i , ví dụ phân bố chuẩn $\mathcal{N}(y_i, \sigma)$ với trung bình y_i và phương sai σ nào đó. Tất nhiên, chúng ta cũng có thể nói là dữ liệu không bị đo sai, mà chẳng qua hàm sinh của chúng ta có tính ngẫu nhiên với

$$y = ax + b + \mathcal{N}(0, \sigma).$$

Nói một cách khác, mô hình sinh của chúng ta là

$$p(y|x) = f(y - (ax + b)),$$

với f là hàm density của $\mathcal{N}(0, \sigma)$.

Ta đã có đủ công cụ để biểu diễn bài toán dưới góc độ xác suất. Cụ thể, với tham số $\theta = (a, b)$, ta có likelihood

$$p((x_1, y_1), \dots, (x_n, y_n) | \theta) \sim \prod_i f(y_i - (ax_i + b)).$$

Bài tập 45. Tại sao ở trên không phải dấu bằng mà là dấu tỉ lệ $\sim$?

Lưu ý ta chỉ mô phỏng $p(y|x)$ khi biết θ mà không hề mô phỏng $p(x)$. Chúng ta có thể giả định $p(x)$ là uniform nếu muốn. Thông thường trong các bài có dạng input-output $x \rightarrow y$ thì ta không thật quan tâm x được phân bố thế nào (lưu ý là chỉ là thông thường là vậy).

Bài tập 46. Hãy tìm một họ phân bố xác suất để bài toán maximum likelihood sẽ tương ứng với hàm lỗi tổng bình phương khoảng cách.

Lưu ý là ngôn ngữ xác suất thường mạnh hơn những hàm lỗi được thiết kế cảm tính. Cụ thể, ta có thể sử dụng công cụ xác suất tiên nghiệm, cập nhật nhiều lần với hậu nghiệm, đưa phần bố của input x vào mô hình.

7 Tối ưu hoá

Thông thường để tối ưu hoá một hàm, chúng ta tìm các điểm cực trị của hàm đó. Nói cách khác, với hàm $f(x)$ ta cần tìm các giá trị x sao cho $f'(x) = 0$. Việc điểm cực trị là cực đại hay cực tiểu sẽ phụ thuộc vào đạo hàm bậc hai $f''(x)$ là dương hay âm.

Tuy nhiên, cách thức trên chỉ thật sự hiệu quả với những hàm có các tính chất đủ đẹp. Ví dụ, nếu $f(x)$ là đa thức bậc ba thì $f'(x)$ là đa thức bậc hai, khi đó ta chỉ cần quan tâm tối đa 2 điểm uốn. Ngược lại, nếu $f(x)$ là đa thức bậc 6 thì đạo hàm khi này là đa thức bậc 5 không cho phép chúng ta tìm nghiệm ở dạng closed-form.

Dẫu điều trên không thật tích cực thì chúng ta cũng đã có mối liên hệ giữa tối ưu hoá và bài toán tìm nghiệm. Việc một đa thức bậc lớn hơn 4 không có nghiệm closed-form không có nghĩa chúng ta không thể tìm xấp xỉ chúng bằng các phương pháp numerical. Thật vậy, nếu một hàm g là liên tục trên khoảng $[a, b]$ và chúng ta biết $g(a) \geq 0$ và $g(b) \leq 0$ thì chúng ta biết rằng một giá trị x nào đấy thuộc khoảng $[a, b]$ thoả mãn $g(x) = 0$.

Bài tập 47. Đọc lại khái niệm liên tục của hàm số và chứng minh điều trên.

Ta có thể tiến hành kỹ thuật “binary-search” trên khoảng $[a, b]$ để tìm kiếm điểm x này. Chúng ta có thể đơn thuần chia đôi tại điểm $c = (a + b)/2$ và tùy thuộc vào dấu của $g(c)$ mà chúng ta sẽ tiến hành tìm kiếm tiếp trên khoảng $[a, c]$ hay $[c, b]$. Kích thước khoảng sẽ bị chia đôi tại mỗi lần và chúng ta dừng khi khoảng đủ nhỏ.

Tuy nhiên, như thế nào là đủ nhỏ? Liệu đó có phải là khi kích thước khoảng nhỏ hơn một $\epsilon = .0001$ nào đấy? Nhưng rõ ràng chúng ta đang quan tâm tới giá trị của $g(x)$ có gần 0 hay không. Có vẻ điều kiện nên là $|g(x)| < \epsilon$

thì hơn. Nhưng cũng không hẳn, vì suy cho cùng thì $g(x)$ thật sự là đạo hàm của một hàm $f(x)$ nào đấy. Và cái chúng ta thật sự quan tâm có lẽ nên là

$$\frac{|f(x) - f(x^*)|}{f(x^*)} < \epsilon$$

trong đó x^* là một điểm cực trị của hàm $f(x)$. Chúng ta có thể nói gì về tương quan giữa tỉ lệ trên và $|g(x)|$. Nói cách khác, $|g(x)|$ nhỏ hơn bao nhiêu thì tỉ lệ trên nhỏ hơn ϵ ?

Bài tập 48. Hãy kiểm tra xem liệu chúng ta có thể tạo được mối liên hệ như trên không? Lưu ý đối chiếu với định nghĩa đạo hàm!

Giả sử ta không thật sự quan tâm $f(x)$ có đủ gần $f(x^*)$ không mà quan tâm x có gần x^* không. Nói cách khác, đại lượng quan tâm là

$$\frac{|x - x^*|}{x^*}.$$

Bài tập 49. Giải lại bài tập trên với đại lượng mới này.

Nếu để ý sẽ thấy x^* và $f(x^*)$ ở mẫu đều có thể là 0 làm cho phân số vô nghĩa. Tuy nhiên, chúng lại cần thiết để phản ánh độ chính xác tham chiếu trên đại lượng này.

Bài tập 50. Điều chỉnh biểu thức điều kiện để chúng cover được cả trường hợp này.

Như vậy chúng ta có thể thấy thuật toán binary-search cho phép chúng ta có được một chuỗi hội tụ tới giá trị x^* cần tìm. Tuy nhiên, khi dừng tại một bước n bất kì, chúng ta không có ý niệm gì về việc còn bao xa thì tới x^* . Để có thể ước lượng được tốc độ hội tụ có lẽ chúng ta cần nhiều thông tin hơn về $f(x)$.

8 Duality của bài toán tối ưu và bài toán tìm nghiệm

Chúng ta đã chỉ ra rằng để giải bài toán tối ưu một hàm, chúng ta chỉ cần tìm nghiệm của đạo hàm của chúng. Điều ngược lại cũng có thể. Cho một bài toán tìm nghiệm phương trình $f(x) = a$, chúng ta chỉ cần tối thiểu hoá độ sai khác giữa $f(x)$ và a . Độ sai khác này có thể đo bằng nhiều cách khác nhau. Giả sử chúng ta bắt đầu với $g(x) = |f(x) - a|$. Khi này chúng ta chỉ cần tối thiểu hoá hàm $g(x)$. Bản thân hàm $g(x)$ không âm nên thực ra đây là tìm giá trị gần 0 nhất có thể. Để giải bài toán tối ưu hoá này, ta lại cần

quan tâm đạo hàm $g'(x)$. Nhưng vấn đề nằm ở đây là để xác định được $g'(x)$ thì chúng ta lại phải xác định được tại mỗi x thì $f(x)$ lớn hơn hay nhỏ hơn a . Điều này làm phức tạp hoá vấn đề lên rất nhiều.

Tuy nhiên, như đã nói ở các phần trước, chúng ta không nhất thiết phải dùng hàm trị tuyệt đối, thứ có tính chất toán học không đẹp, mà có thể dùng hàm bình phương khoảng cách, thứ đẹp hơn mà vẫn tăng đồng điệu với hàm trị tuyệt đối. Nói cách khác, chúng ta sẽ tối thiểu hoá hàm

$$g(x) = (f(x) - a)^2.$$

Bài tập 51. Hãy thử phương án trên với phương trình $x^5 = 32$?

Giải bài tập trên chúng ta sẽ bắt gặp vấn đề con gà quả trứng: bài toán A qui về bài toán B rồi lại qui về bài toán A . Tuy điều này không giúp ta giải bài toán nhưng cho ta mối tương quan giữa 2 bài toán theo nghĩa: một lời giải cho bài toán này sẽ kéo theo một lời giải cho bài toán kia.

Bài tập 52. Hãy thử với hàm bậc bốn khoảng cách $(f(x) - a)^4$ cho bài tập trên. Liệu chúng ta có đang đi quá xa?

9 Đạo hàm và Taylor series

Trong cả bài toán tìm nghiệm và tối ưu, đạo hàm cho phép chúng ta có ý niệm về đồ thị của hàm $y = f(x)$ trong khoảng lân cận x . Cụ thể, ta có thể xấp xỉ hàm $y = f(x)$ bằng $z = f(x_0) + f'(x_0)(x - x_0)$. Hiển nhiên là đường thẳng $z = g(x)$ này sẽ rất sai khác với $y = f(x)$. Tuy nhiên trong khoảng $[x_0 - \epsilon, x_0 + \epsilon]$ với ϵ đủ bé thì đó không phải là một ước lượng tệ.

Phương án trên cho phép chúng ta xấp xỉ hàm tại một điểm cục bộ. Thế còn xấp xỉ toàn cục hơn chút sẽ như thế nào? Giả sử chúng ta được cho hai giá trị $y_1 = f(x_1)$ và $y_2 = f(x_2)$ mà không được cho thông tin về đạo hàm. Khi này, hàm xấp xỉ sẽ là dây cung nối hai điểm (x_1, y_1) và (x_2, y_2) .

Giả sử chúng ta được cho 3 giá trị $y_i = f(x_i)$ với $i = 1, 2, 3$. Lúc này một đường thẳng sẽ không dễ dàng để đi qua 3 điểm. Hãy tưởng tượng $x_0 = 0, x_1 = \pi/2, x_2 = \pi$ với trường hợp $f(x) = \sin(x)$. Khi này 3 điểm sẽ là 3 đỉnh của một tam giác, và một đường cong parabol bậc 2 có lẽ sẽ phù hợp hơn để xấp xỉ nó.

Bài tập 53. Hãy tính đường bậc 2 trong trường hợp này.

Ở khía cạnh ngược lại, chúng ta xấp xỉ ra sao nếu như có các giá trị $f(x_0), f'(x_0), f''(x_0)$ tại một điểm x_0 . Một đường cong bậc 2 sẽ cần thoả mãn những ràng buộc gì ở đây? Tương tự như đi qua 3 điểm, ta cần hàm $z = ax^2 + bx + c$ sao cho $z(x_0) = f(x_0), z'(x_0) = f'(x_0), z''(x_0) = f''(x_0)$.

Bài tập 54. Hãy tính hàm $z(x)$ với $f(x) = \sin(x)$ và $x_0 = \pi/2$. So sánh kết quả với bài tập trên.

Một thủ thuật để giải bài trên dễ dàng là viết $z = a(x - \pi/2)^2 + b(x - \pi/2) + c$. Lúc này, khi lấy đạo hàm các bậc chúng sẽ triệt tiêu với các hạng tử bằng 0 và mọi thứ dễ dàng hơn. Chúng ta cũng có thể cảm nhận bóng dáng của chuỗi Taylor ở đây.

Xét rộng hơn thì khi có $k + 1$ đạo hàm các bậc tăng dần $f(x_0), f'(x_0), \dots, f^{(k)}(x_0)$, chúng ta cũng có thể làm điều tương tự.

Bài tập 55. Hãy tính đa thức đó!

10 Gradient descent (phiên bản một chiều)

Khi nhìn vào một điểm x_0 và chúng ta biết đường thẳng xấp xỉ hàm tại điểm đó, chúng ta muốn di chuyển x_0 về một vị trí mới x_1 sao cho $f(x_1)$ nhỏ hơn $f(x_0)$. Nói cách khác x_1 sẽ gần hơn x^* nào đấy tối thiểu hoá (có thể cục bộ) hàm $f(x)$.

Hướng (tức dấu) của đạo hàm sẽ xác định việc chúng ta di chuyển sang phải hay trái. Tuy nhiên độ lớn của bước di chuyển là một câu hỏi. Chúng ta muốn di chuyển nhanh với số bước ít nhất, nhưng nếu di chuyển một bước dài quá thì có thể làm x_1 thậm chí xa rời x^* hơn x_0 . Công thức chung cho việc này là chúng ta sẽ di chuyển một số lần nào đấy của đạo hàm. Hay nói cách khác,

$$x_1 = x_0 - \alpha f'(x_0).$$

Tỉ lệ α gọi là learning rate. Trong những cài đặt phức tạp thì tỉ lệ này có thể không cố định. Nhưng trong phạm vi ở đây, α sẽ được duy trì trong mọi bước. Cụ thể, ở bước tiếp theo, ta cũng có

$$x_2 = x_1 - \alpha f'(x_1).$$

Và các bước sau cũng lặp lại như thế với hy vọng nhận được một chuỗi $x_0, x_1, \dots$ hội tụ tới x^* .

Tuy nhiên, điều này còn phụ thuộc α thế nào. Ví dụ với hàm $f(x) = x^2$ và bắt đầu với $x_0 = 1$. Đạo hàm khi này là $f'(x) = 2x$. Nếu $\alpha = 1$ thì $x_1 = x_0 - \alpha f'(x_0) = 1 - 2 = -1$ và $x_2 = -1 + 2 = 1$. Nói cách khác chuỗi chúng ta nhận được là $x_0, x_1, \dots = 1, -1, 1, -1, \dots$. Chúng nhảy qua lại 1, -1 và không bao giờ hội tụ tới $x^* = 0$ nơi $f(x)$ đạt cực tiểu.

Bài tập 56. Liệu chuỗi sẽ hội tụ ngay khi α là giá trị bất kì nhỏ hơn 1?

Trong thực tế, giá trị α thường được cài đặt dựa trên cảm tính và đủ nhỏ. Thậm chí sẽ được chọn theo việc thử: nếu thấy không thấy hội tụ thì lại giảm tiếp. Tuy nhiên cảm tính chưa bao giờ là chặt chẽ, và “nhìn” vào phần đầu một chuỗi chúng ta cũng không bao giờ chắc chắn được nó có hội tụ hay không.

Bài tập 57. Nếu ta đặt $\alpha = .0001$, hãy cho một hàm (bậc 2 chẳng hạn) sao cho bắt đầu bằng $x_0 = 1$ sẽ không hội tụ!

Bài tập 58. Cho trước một hàm $f(x) = ax^2 + bx + c$ và điểm bắt đầu $x_0 = 1$. Hãy tính α lớn nhất sao cho chuỗi hội tụ!

Như vậy α quá lớn sẽ gây ra overshooting, x_1 sẽ nhảy sang phía bên kia của x^* (nói cách khác x^* nằm giữa x_0 và x_1). Bản thân việc nhảy sang bờ bên kia không xấu nếu như khoảng cách vẫn được rút ngắn sau mỗi lần lặp. Tuy nhiên, như đã thấy trong các ví dụ, điều này không được đảm bảo.

Ở chiều hướng ngược lại, nếu đặt α quá nhỏ gây ra vấn đề undershooting. Thuật toán sẽ hội tụ với tốc độ khá chậm.

Bài tập 59. Cho hàm $f(x) = x^2$ và $x_0 = 1$. Biết rằng hai giá trị α_1, α_2 đều thoả mãn hội tụ nhưng $\alpha_1 = \frac{\alpha_2}{2}$. Chúng ta có thể có kết luận gì về tốc độ hội tụ tới x^* của hai chuỗi tương ứng?

11 Newton method

Nếu như gradient descent là thuật toán ta nghĩ tới đầu tiên cho tối ưu hoá thì Newton method là thuật toán tương ứng cho giải phương trình. Cụ thể, để giải phương trình $f(x) = 0$, ta cũng bắt đầu bằng một điểm ban đầu phỏng đoán $x = x_0$. Lúc này, ta có đường thẳng xấp xỉ $f(x)$ tại khu vực lân cận $x \in [x_0 - \epsilon, x_0 + \epsilon]$ là $\ell(x) = f(x_0) + f'(x_0)(x - x_0)$. Cho dù chúng ta không thật sự biết đường thẳng này xấp xỉ $y = f(x)$ tốt thế nào khi x xa rời x_0 , tuy nhiên ta vẫn “mạnh dạn” giải phương trình đơn giản $\ell(x) = 0$ với hy vọng lời giải cũng sẽ tiệm cận tới nghiệm của $f(x) = 0$. Về mặt hình học, lúc này ta xem xét điểm cắt của đường tiếp tuyến tại $x = x_0$ với đường ngang $y = 0$. Giá trị nghiệm

$$x_0 - \frac{f(x_0)}{f'(x_0)}$$

sẽ là giá trị trong vòng lặp tiếp theo x_1 . Và các giá trị $x_2, x_3, \dots$ sẽ được kỳ vọng là tiến tới giá trị x^* với $f(x^*) = 0$.

Bài tập 60. Xét hàm số $y = x^2 - 1$. Chúng ta bắt đầu với $x_0 = 2$. Cho trước một ϵ nào đó. Hỏi sau bao nhiêu vòng lặp thì (i) $|f(x_n)| < \epsilon$, (ii) $|x_n - x^*| < \epsilon$ (đại lượng hoá số vòng lặp n cần thiết theo ϵ).

12 Tương quan qua lại giữa Gradient descent và Newton method

Chúng ta đều biết tối ưu hoá và giải phương trình là hai bài toán dual. Giả sử chúng ta phải giải bài toán nghiệm phương trình $f(x) = 0$ mà chúng ta lại chưa học phần Newton method. Lúc này chúng ta phải tối ưu hoá hàm $g(x) = [f(x)]^2$. Đạo hàm là $g'(x) = 2f(x)f'(x)$ và bước cập nhật tại mỗi lượt là³

$$x_{n+1} = x_n - \alpha f(x_n) f'(x_n).$$

Trong khi đó, Newton method lại dùng

$$x_{n+1} = x_n - \frac{f'(x_n)}{f(x_n)}.$$

Bài tập 61. Hai công thức trên nhìn hoàn toàn khác biệt, thậm chí là trái ngược, khi đại lượng được trừ là tích và phân số. Có sai sót gì ở đây không? Cái nào tốt hơn?

Ở chiều hướng ngược lại, giả sử chúng ta chỉ được học Newton method mà phải đối mặt bài toán tối ưu hoá hàm $f(x)$. Nói cách khác chúng ta giải $g(x) = 0$ với $g(x) = f'(x)$ với Newton method. Bước cập nhật sẽ là

$$x_{n+1} = x_n - \frac{f''(x_n)}{f'(x_n)}.$$

Một lần nữa, chúng ta lại thấy sự khác biệt khi không thấy chúng liên quan gì tới bước cập nhật trong gradient descent:

$$x_{n+1} = x_n - \alpha f'(x_n).$$

Bài tập 62. Các đại lượng $f'(x)$ và $f''(x)/f'(x)$ liệu có thể được liên hệ với nhau theo cách nào không?

13 Mối liên hệ giữa Taylor series và Newton method

Xấp xỉ Taylor bậc 1 của $f(x)$ (tức dùng đạo hàm bậc 1 duy nhất) cho ra đường tiếp tuyến

$$\ell(x) = f(x_0) + f'(x_0)(x - x_0).$$

³Ta không viết số 2 trong bước cập nhật dưới đây vì nó có thể được “nhúng” trong α .

Như đã trình bày trước đây, bước cập nhật

$$x_1 = x_0 - \frac{f'(x_0)}{f(x_0)}$$

chính là nghiệm của phương trình trên.

Khi chúng ta dùng Newton method để tối ưu hoá với bước cập nhật

$$x_1 = x_0 - \frac{f''(x_0)}{f'(x_0)},$$

chúng ta có thể xem xét xấp xỉ bậc 2 Taylor của $f(x)$ tại x_0 :

$$p(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2}f''(x_0)(x - x_0)^2.$$

Vì hàm $p(x)$ là một xấp xỉ của hàm $f(x)$, vì thế chúng ta mong đợi giá trị tối ưu hoá hàm $p(x)$ sẽ cho ta một giá trị gần x^* hơn là x_0 .

Bài tập 63. Hãy kiểm chứng lại xem bước cập nhật trong Newton method cho bài toán tối ưu hoá cũng chính là giá trị tối ưu hoá $p(x)$ trên.

Ở góc độ bài toán tối ưu hoá, gradient descent là phương pháp tối ưu bậc 1 và Newton method là tối ưu bậc hai (dựa trên bậc cao nhất của đạo hàm được dùng). Trên thực tế, dựa trên Taylor series, chúng ta có thể áp dụng tối ưu hoá bậc cao hơn.

Bài tập 64. Viết công thức cập nhật với bậc k nào đấy. (Đa thức bậc cao thường không có lời giải closed-form, có cách nào hợp lí ở đây không?)

Bài tập 65. Với hàm $f(x) = x^2$ và bắt đầu với $x_0 = 1$, hãy đưa ra so sánh về tốc độ hội tụ khi ta sử dụng Taylor series với các bậc k khác nhau.

Hiển nhiên bài tập trên không có nghĩa là ta sẽ “mù quáng” áp dụng các bậc cao: Tuy tốc độ hội tụ có thể nhanh hơn nhưng chúng ta lại tốn chi phí hơn tại mỗi lần lặp khi mà phải tính nhiều đạo hàm hơn. Trên thực tế rất hiếm khi chúng ta dùng bậc cao hơn như là trong Newton method.

Suy cho cùng thì Newton method mục đích ban đầu là giải phương trình bằng cách cập nhật phỏng đoán thông qua giải nghiệm một hàm xấp xỉ, cụ thể là hàm xấp xỉ tuyến tính (Taylor bậc 1). Tại sao không mở rộng lên?

Bài tập 66. Hãy sử dụng Taylor series bậc 2 để cập nhật lại x_n trong Newton method! Hãy xem xét hệ quả khi áp dụng thuật toán giải phương trình mới này trong bài toán tối ưu hoá. Thử nghiệm chúng trên hàm $f(x) = x^2$.

14 Tăng tốc hội tụ

15 Hàm lỗi