

Contents

Đề cương ôn tập thi giữa kỳ môn Học máy	1
Tổng quan	1
Chương 1. Giới thiệu về Học máy	1
Chương 2. Hồi quy tuyến tính	2
Chương 3. Phân lớp	4
Chương 4. Tổng quát hóa & Kiểm định chéo	5
Chương 5. Lựa chọn mô hình & Điều chuẩn	6
Chương 6. Phi tuyến hoá	7
Chương 7. Giảm chiều dữ liệu	8
Chương 8. Phân cụm	9
Chương 9. Cây quyết định & Ensemble	11
Chương 10. Support Vector Machines	12

Đề cương ôn tập thi giữa kỳ môn Học máy

Tổng quan

#	Chủ đề	Trọng tâm
1	Giới thiệu về Học máy	Khái niệm, paradigms, bias–variance
2	Hồi quy tuyến tính	OLS, suy luận thống kê, chẩn đoán
3	Phân lớp	Logistic, LDA/QDA, k-NN, ROC/AUC
4	Tổng quát hóa & Kiểm định chéo	Bias–variance, K-fold, Bootstrap
5	Lựa chọn mô hình & Điều chuẩn	Ridge, Lasso, AIC/BIC, 1-SE
6	Phi tuyến hoá	Spline, GAM, Loess
7	Giảm chiều dữ liệu	PCA, MDS, biplot
8	Phân cụm	K-means, Hierarchical, linkage
9	Cây quyết định & Ensemble	Cây, Bagging, Random Forest, Boosting
10	Máy vector hỗ trợ	Phân lớp lề cực đại, lề mềm, kernel

Lưu ý chung khi ôn:

- Học theo thứ tự: **định nghĩa** → **công thức** → **diễn giải khi đọc bảng/đồ thị**.
- Ưu tiên **so sánh theo cặp**: parametric vs non-parametric, LDA vs QDA, Ridge vs Lasso, K-means vs HAC, Bagging vs Boosting, MMC vs SVM, ...
- Tập đọc đồ thị: residual plot, ROC, scree plot, dendrogram, learning curve, regularization path.
- Mỗi mô hình cần biết: **giả định**, **hàm mất mát**, **siêu tham số**, **bias–variance trade-off**, **ưu/nhược**.

Chương 1. Giới thiệu về Học máy

Mục tiêu học

- Nói rõ học máy là gì và khi nào **nên** / **không nên** dùng học máy.

- Phân loại bài toán theo paradigm (giám sát / không giám sát / bán giám sát / tăng cường) và theo loại đầu ra (hồi quy / phân lớp).
- Mô tả được chu trình *ML pipeline* và phân rã sai số bias-variance.

Khái niệm cốt lõi

- **Định nghĩa Tom Mitchell (T-P-E):** một chương trình học nếu hiệu năng P trên tác vụ T cải thiện theo kinh nghiệm E .
- **Khi nào dùng ML:** dữ liệu sẵn có & quy luật khó viết bằng if-else; **không nên** khi quy tắc đã rõ, dữ liệu quá ít/không đại diện, hoặc lỗi sai gây hậu quả không chấp nhận được.
- **Paradigms:** giám sát (có nhãn) / không giám sát / bán giám sát / tăng cường (reward).
- **Loại đầu ra:** hồi quy (liên tục) vs phân lớp (rời rạc); phân biệt mô hình **sinh** (generative) vs **phân biệt** (discriminative).
- **Tham số vs phi tham số:** có giả định dạng hàm cố định, ít tham số, ít dữ liệu vẫn dùng được vs linh hoạt, cần nhiều dữ liệu (ví dụ k-NN).
- **Mô hình diễn giải vs hộp đen:** đánh đổi $accuracy \leftrightarrow interpretability$.
- **Pipeline ML:** thu thập $\rightarrow$ tiền xử lý $\rightarrow$ đặc trưng $\rightarrow$ huấn luyện $\rightarrow$ đánh giá $\rightarrow$ triển khai $\rightarrow$ giám sát.
- **Bayes Classifier & Bayes error rate:** giới hạn dưới của test error.
- **Naïve Bayes:** giả định độc lập có điều kiện giữa các đặc trưng cho lớp.

Công thức cần nhớ

$$Y = f(X) + \varepsilon, \quad \mathbb{E}[(Y - \hat{f}(X))^2] = \text{Bias}^2 + \text{Variance} + \sigma^2$$

$$\text{MSE} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2, \quad \text{Acc} = \frac{TP+TN}{TP+TN+FP+FN}$$

Lỗi/hiệu sai phổ biến

- Nhầm “mô hình phức tạp = tốt hơn”.
- Cho rằng học có giám sát chỉ là phân lớp (quên hồi quy).
- Coi *training error* nhỏ là đủ — bỏ qua test error.

Chương 2. Hồi quy tuyến tính

Mục tiêu học

- Viết và giải nghiệm OLS dạng đóng.
- Kiểm tra giả định và chẩn đoán bằng đồ thị phần dư.
- Xử lý đa cộng tuyến, biến tương tác, biến định tính.

Khái niệm cốt lõi

- **Mô hình:** $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon$. Khi dự đoán: $\hat{Y} = X\hat{\beta}$ (không có ε).
- **OLS:** tối thiểu $\text{RSS} = \sum (y_i - \hat{y}_i)^2$.
- **Nghiệm dạng đóng:** $\hat{\beta} = (X^T X)^{-1} X^T y$.
- **Đường OLS** đi qua điểm trung bình $(\bar{x}, \bar{y})$.

- **Định lý Gauss–Markov:** OLS là **BLUE** (Best Linear Unbiased Estimator) khi ε có kỳ vọng 0, đồng phương sai, không tương quan.
- **Phần dư:** $e_i = y_i - \hat{y}_i$.

Suy luận thống kê

- **SE** đo độ biến thiên của $\hat{\beta}$ qua các mẫu.
- $t = \hat{\beta}_j / \text{SE}(\hat{\beta}_j)$, kiểm định $H_0 : \beta_j = 0$. $|t|$ lớn $\Leftrightarrow$ **p-value nhỏ**.
- **F-test** cho ý nghĩa toàn mô hình.
- **Khoảng tin cậy 95 %:** $\hat{\beta}_j \pm 1.96 \cdot \text{SE}$.

Đo lường mô hình

- $R^2 = 1 - \text{RSS}/\text{TSS}$.
- $\text{RSE} = \sqrt{\text{RSS}/(n - p - 1)}$.
- R^2 **tăng đơn điệu** khi thêm biến $\rightarrow$ cần Adjusted R^2 để so sánh mô hình khác số biến.

Diễn giải hệ số

“Khi X_j tăng 1 đơn vị, Y thay đổi $\hat{\beta}_j$ đơn vị, **giữ các biến khác không đổi**”. Intercept = giá trị Y kỳ vọng khi mọi $X = 0$.

Giả định & chẩn đoán

- **Giả định:** tuyến tính, độc lập, đồng phương sai (homoskedasticity), sai số phân phối chuẩn (cho suy luận), không đa cộng tuyến hoàn hảo.
- **Residual plot hình chữ U** $\Rightarrow$ quan hệ phi tuyến chưa được mô hình hóa.
- **Heteroskedasticity** $\Rightarrow$ residual có hình phễu; có thể biến đổi log.
- **Đa cộng tuyến (Multicollinearity):** SE tăng, $\hat{\beta}$ không ổn định nhưng vẫn không chệch. Đo bằng **VIF**: $\text{VIF}_j = 1/(1 - R_j^2)$; $\text{VIF} > 5-10$ là cờ cảnh báo.

Mở rộng

- **Biến định tính (Dummy):** k mức $\Rightarrow k - 1$ biến giả.
- **Tương tác:** $\beta_3 X_1 X_2$ — hệ số phụ thuộc giá trị biến kia.
- **Đa thức: tuyến tính theo tham số**, vẫn giải bằng OLS.
- **Lựa chọn biến:** Forward (rỗng $\rightarrow$ thêm), Backward (đầy $\rightarrow$ loại), Best subset (2^p mô hình — không khả thi khi p lớn).
- **k-NN regression:** trung bình k láng giềng gần nhất; phi tham số; bị **lời nguyền chiều cao**.

Tương quan $\neq$ nhân quả

Cần xét biến ẩn (confounder); **Simpson’s paradox** — kết luận đảo ngược khi gộp/tách nhóm.

Chương 3. Phân lớp

Mục tiêu học

- So sánh được Logistic, LDA, QDA, k-NN về giả định, biên quyết định, độ phức tạp.
- Đánh giá mô hình phân lớp bằng confusion matrix, ROC/AUC, Sensitivity/Specificity.

Vì sao không dùng OLS cho phân lớp?

- Xác suất ngoài $[0, 1]$.
- Với $K > 2$ áp đặt thứ tự giả tạo cho lớp.

Logistic regression

- $p(X) = \sigma(\beta_0 + \beta^T X) = \frac{e^{\beta_0 + \beta^T X}}{1 + e^{\beta_0 + \beta^T X}}$.
- **Logit / log-odds:** $\log \frac{p}{1-p} = \beta_0 + \beta^T X$.
- **Odds:** $p/(1-p)$.
- Ước lượng bằng **MLE** (không có dạng đóng) — tối ưu bằng Newton–Raphson / gradient.
- $\beta_j \approx$ thay đổi log-odds khi X_j tăng 1 đơn vị.

Phân lớp Bayes

$$P(Y = k | X) = \frac{\pi_k f_k(x)}{\sum_l \pi_l f_l(x)}.$$

LDA & QDA

- **LDA:** giả định $f_k(x) \sim \mathcal{N}(\mu_k, \Sigma)$ — **chung** Σ . Hàm phân biệt tuyến tính:

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k.$$

- **QDA:** mỗi lớp có Σ_k riêng $\Rightarrow$ biên **bậc hai**, nhiều tham số hơn ($Kp(p+1)/2$ vs $p(p+1)/2$ của LDA) $\Rightarrow$ dễ overfit.

k-NN classification

Phi tham số; k nhỏ $\Rightarrow$ phương sai cao (biên gồ ghề), k lớn $\Rightarrow$ thiên lệch cao (biên trơn).

Bias-variance: LDA $\rightarrow$ QDA $\rightarrow$ k-NN linh hoạt dần.

Đánh giá phân lớp

Chỉ số	Công thức	Khi cần
Accuracy	$(TP + TN)/N$	dữ liệu cân bằng
Sensitivity / Recall (TPR)	$TP/(TP + FN)$	phát hiện positive
Specificity (TNR)	$TN/(TN + FP)$	tránh false alarm

Chỉ số	Công thức	Khi cần
Precision (PPV)	$TP/(TP + FP)$	chi phí FP cao
F1	$2PR/(P + R)$	imbalanced

- **ROC:** trục x = 1 — Specificity (FPR), trục y = Sensitivity (TPR); thay đổi ngưỡng phân lớp.
- **AUC $\in [0,1]$:** 0.5 = ngẫu nhiên; 1 = hoàn hảo.
- **Hạn chế Accuracy** trên dữ liệu mất cân bằng.

Khi nào chọn cái gì?

- Giả định Gauss + Σ chung đúng $\rightarrow$ LDA.
- Σ rất khác giữa lớp + đủ dữ liệu $\rightarrow$ QDA.
- Biên phi tuyến phức tạp, không có giả định $\rightarrow$ k-NN.
- Cần xác suất + diễn giải hệ số $\rightarrow$ Logistic.

Chương 4. Tổng quát hóa & Kiểm định chéo

Mục tiêu học

- Phân biệt train / validation / test; chọn đúng phương pháp đánh giá.
- Phân rã expected test MSE thành $\text{Bias}^2 + \text{Variance} + \sigma^2$.
- Tránh **rò rỉ dữ liệu** khi tiền xử lý + CV.

Khái niệm cốt lõi

- **Quá khớp (overfit):** train error thấp, test error cao.
- **Dưới khớp (underfit):** train + test đều cao.
- **Bias–Variance trade-off:** tăng độ phức tạp $\Rightarrow$ Bias $\downarrow$, Variance $\uparrow$; test error có dạng chữ U.

Các phương pháp đánh giá

- **Validation set:** ước lượng đơn giản nhưng phương sai cao; phụ thuộc cách chia.
- **K-Fold CV:** trung bình lỗi qua K lần; $K = 5, 10$ phổ biến.
- **LOOCV:** $K = n$; bias thấp, variance cao, tính cực đắt với mô hình tổng quát; với OLS có công thức rút gọn $\frac{1}{n} \sum [(y_i - \hat{y}_i)/(1 - h_{ii})]^2$.
- **Stratified K-Fold:** giữ tỷ lệ lớp — bắt buộc khi imbalanced.
- **Nested CV:** vòng trong tune siêu tham số, vòng ngoài đánh giá.

Bootstrap

- Lấy mẫu **có hoàn lại**, kích thước n .
- Xác suất một quan sát **không** xuất hiện trong mẫu khi $n \rightarrow \infty$: $(1 - 1/n)^n \rightarrow e^{-1} \approx 0.368 \Rightarrow \text{OOB} \approx 36.8\%$.
- Bootstrap **không phù hợp** ước lượng prediction error trực tiếp (overfit), nhưng tốt cho ước lượng SE/CI và OOB cho ensemble.

Quy tắc 1-SE

Chọn mô hình **đơn giản nhất** có $CV \text{ error} \leq \min + 1 \text{ SE}$.

Bẫy CV thường gặp

- Chuẩn hoá toàn bộ dữ liệu **trước** khi chia $\Rightarrow$ rò rỉ.
- Chuỗi thời gian phải dùng *time-series split* (không xáo trộn).

Learning curve

- $\text{Train} \uparrow + \text{val} \uparrow$ hội tụ $\rightarrow$ underfit.
- Gap lớn giữa train và val $\rightarrow$ overfit $\Rightarrow$ thêm dữ liệu hoặc giảm độ phức tạp.

Công thức then chốt

$$\mathbb{E}[(y_0 - \hat{f}(x_0))^2] = \text{Bias}(\hat{f}(x_0))^2 + \text{Var}(\hat{f}(x_0)) + \sigma^2.$$

Chương 5. Lựa chọn mô hình & Điều chuẩn

Mục tiêu học

- Hiểu trực giác hình học và đại số của Ridge & Lasso.
- Chọn λ bằng CV / 1-SE.
- Quyết định khi nào dùng Ridge, Lasso, Elastic Net, Best/Forward/Backward subset.

Lựa chọn tập con biến

- **Best subset:** 2^p mô hình — chỉ khả thi khi $p \lesssim 30$.
- **Forward stepwise:** $1 + p(p+1)/2$ mô hình — luôn khả thi.
- **Backward stepwise:** bắt đầu mô hình đầy, loại biến đóng góp thấp nhất; cần $n > p$.

Ridge (L_2)

$$\hat{\beta}^{\text{ridge}} = \arg \min \|y - X\beta\|^2 + \lambda \|\beta\|_2^2, \quad \hat{\beta} = (X^T X + \lambda I)^{-1} X^T y.$$

- Co hệ số nhưng **không bằng 0**. - Xử lý đa cộng tuyến tốt. - Effective DoF giảm khi λ tăng.

Lasso (L_1)

$$\hat{\beta}^{\text{lasso}} = \arg \min \|y - X\beta\|^2 + \lambda \|\beta\|_1.$$

- Tạo **nghiệm thừa** (một số β_j chính xác = 0) — vừa shrink vừa **chọn biến**.

Trực giác hình học

- Ellipse RSS chạm hình thoi L_1 tại đỉnh nhọn $\Rightarrow$ một $\beta_j = 0$.
- Chạm hình tròn $L_2 \Rightarrow$ không zero out.

Trường hợp $n = p$, $X = I$

- Ridge: $\hat{\beta}_j = y_j / (1 + \lambda)$ (co đều).
- Lasso: $\hat{\beta}_j = \text{sign}(y_j) \max(|y_j| - \lambda/2, 0)$ (soft-thresholding).

Khi nào dùng cái nào?

- Mọi biến đóng góp nhỏ (mô hình “dày”) $\Rightarrow$ **Ridge**.
- $p \gg n$, chỉ vài biến thật sự liên quan (sparse) $\Rightarrow$ **Lasso**.
- Đa cộng tuyến cao ($\text{VIF} > 20$) $\Rightarrow$ **Ridge**.
- Cần parsimony + diễn giải $\Rightarrow$ **Lasso + 1-SE**.
- Cả hai ưu điểm + nhóm tương quan $\Rightarrow$ **Elastic Net**.

Chọn λ

Lưới giá trị (log-scale) + K -fold CV + chọn min hoặc 1-SE.

Tiêu chí thông tin (chỉ cho linear/Gaussian)

- $C_p = \frac{1}{n}(\text{RSS} + 2d\hat{\sigma}^2)$
- $\text{AIC} \propto C_p$
- $\text{BIC} = \frac{1}{n}(\text{RSS} + \log(n)d\hat{\sigma}^2)$ — phạt nặng hơn AIC $\Rightarrow$ chọn mô hình nhỏ hơn.
- R_{adj}^2 — phạt nhẹ.

Lưu ý quan trọng

- **Cần chuẩn hoá biến trước Ridge/Lasso** vì penalty phụ thuộc thang đo.
- $p > n$: OLS có vô số nghiệm, training error có thể = 0 nhưng overfit nghiêm trọng $\Rightarrow$ bắt buộc điều chuẩn / chọn biến.

Chương 6. Phi tuyến hoá

Mục tiêu học

- Phân biệt các phương pháp phi tuyến **tham số** (đa thức, step, regression spline, natural spline) và **phi tham số** (smoothing spline, loess).
- Đọc và giải thích đồ thị Wage vs Age (ISLR).

Hồi quy đa thức bậc d

$$y = \beta_0 + \beta_1 x + \dots + \beta_d x^d.$$

Tuyến tính theo tham số. **Dao động mạnh ở biên**; hiếm khi $d > 3-4$.

Hàm bậc thang (step function)

Chia miền X thành $K + 1$ khoảng bằng cutpoints, mỗi đoạn = trung bình Y trong khoảng. Số tham số = $K + 1$.

Spline

- **Đa thức từng mảnh (piecewise polynomial):** mỗi đoạn 1 đa thức bậc d — không ràng buộc $\Rightarrow$ gãy tại knot.
- **Cubic spline:** đa thức bậc 3 từng mảnh + ràng buộc liên tục đến đạo hàm bậc 2 tại K knots $\Rightarrow \text{DoF} = K + 4$. Truncated power basis: $h(x, \xi) = (x - \xi)_+^3$.
- **Natural cubic spline:** thêm ràng buộc tuyến tính ngoài 2 knot biên $\Rightarrow$ giảm dao động ở biên; $\text{DoF} = K$. Hay gặp hơn cubic spline trong thực tế.
- **Vị trí knots:** đặt theo phân vị; **số knots** chọn bằng CV.

Smoothing spline

$$\min_g \sum (y_i - g(x_i))^2 + \lambda \int g''(t)^2 dt.$$

- Nghiệm tối ưu là **natural cubic spline** với knot tại mỗi x_i . - $\lambda \rightarrow \infty$: tiến về OLS tuyến tính. - $\lambda \rightarrow 0$: tiến về interpolation.

Local regression (Loess)

Trọng số kernel giảm theo khoảng cách; **bandwidth** s kiểm soát: lớn $\Rightarrow$ trơn, bias $\uparrow$, variance $\downarrow$.

GAM (Generalized Additive Model)

$$y = \beta_0 + \sum_j f_j(x_j) + \varepsilon,$$

mỗi f_j là spline / loess. Diễn giải tốt nhờ tính cộng nhưng **không** mô hình hóa tương tác trừ khi thêm thủ công $f_{jk}(x_j, x_k)$.

Khi nào chọn?

- 1 hyperparam, tự động $\rightarrow$ smoothing spline.
- Cần phi tuyến từng biến + diễn giải $\rightarrow$ GAM.
- Vùng cục bộ + dữ liệu không đều $\rightarrow$ loess.

Chương 7. Giảm chiều dữ liệu

Mục tiêu học

- Trình bày bài toán tối ưu PCA, mối liên hệ eigenvector–eigenvalue.
- Đọc biplot, scree plot, chọn số thành phần.
- Biết hạn chế PCA và khi nào dùng MDS.

Tại sao giảm chiều?

- Trực quan hóa.
- Giảm noise.
- Chống curse of dimensionality (đặc biệt thuật toán dựa khoảng cách như k-NN, k-means).
- **Không** phải để tăng số mẫu.

PCA — bài toán tối ưu

- Cực đại phương sai khi chiếu: $\max_{\|w\|=1} w^T \Sigma w$.
- **Nghiệm:** w là eigenvector của Σ ứng với eigenvalue lớn nhất.
- Đối ngẫu: cực đại phương sai $\Leftrightarrow$ cực tiểu khoảng cách bình phương đến không gian con chiếu.

Tính chất PCA

- Ma trận hiệp phương sai mẫu: $\Sigma = \frac{1}{n-1} X^T X$ (sau khi center).
- PC trực giao và không tương quan.
- Số PC tối đa = $\min(n-1, p)$.
- **Deflation:** PC2 là eigenvector lớn thứ 2, trực giao với PC1.
- **Standardize trước PCA** khi các biến có thang đo khác nhau (dùng ma trận tương quan thay vì hiệp phương sai).

Chọn số PC

- **PVE:** $\text{PVE}_k = \lambda_k / \sum_l \lambda_l$.
- **Scree plot + điểm khuỷu**, hoặc PVE tích lũy (vd. $\geq 80\%$).

Biplot

Điểm = quan sát ở không gian PC1–PC2; mũi tên = loading; loading cùng hướng $\Rightarrow$ biến tương quan. (USArrests: PC1 $\approx$ mức tội phạm; PC2 chi phối bởi UrbanPop.)

Hạn chế của PCA

- Tuyến tính $\rightarrow$ không mở được manifold cong.
- Phương sai lớn $\neq$ tín hiệu liên quan đến nhân.
- Nhạy outlier.

MDS (Multidimensional Scaling)

Bảo toàn **khoảng cách**; classical MDS với khoảng cách Euclid trùng PCA. Sammon mapping ưu tiên cặp gần.

Công thức nhanh

$$\Sigma w_k = \lambda_k w_k, \quad \text{PC}_k = X w_k, \quad \text{Var}(\text{PC}_k) = \lambda_k.$$

Chương 8. Phân cụm

Mục tiêu học

- Chạy được K-means thủ công trên ví dụ nhỏ.
- Đọc dendrogram, hiểu các phương pháp linkage.
- Chọn khoảng cách + chuẩn hóa phù hợp dữ liệu.

Khái niệm cốt lõi

- **Phân cụm = học không giám sát:** tối đa hóa similarity nội cụm, tối thiểu hóa similarity liên cụm.
- **Phân cụm cứng vs mềm:** mỗi điểm thuộc 1 cụm vs xác suất thành viên.

K-means

- **Hàm mục tiêu:**

$$W = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2.$$

- **Thuật toán Lloyd:** lặp (gán cụm theo khoảng cách $\rightarrow$ cập nhật tâm = trung bình) đến hội tụ.
- Hội tụ về **cực trị địa phương** $\Rightarrow$ chạy nhiều khởi tạo, chọn W nhỏ nhất.
- **k-means++:** chọn tâm khởi tạo theo xác suất tỉ lệ với bình phương khoảng cách đến tâm gần nhất.
- **Nhạy outlier** vì dùng trung bình.
- **Thất bại** với cụm phi lồi (two moons).

K-medoids (PAM)

- Tâm là **điểm dữ liệu thực**.
- Ít nhạy với outlier.
- Hoạt động khi chỉ có ma trận bất đồng (không cần toạ độ).

Chọn K

- **Elbow Method:** vẽ W vs K , chọn điểm khuỷu.
- Silhouette, Gap statistic (nâng cao).

Hierarchical Agglomerative Clustering (HAC)

- Tích tụ (bottom-up): mỗi điểm 1 cụm $\rightarrow$ gộp dần.
- Chia (top-down): cả tập là 1 cụm $\rightarrow$ tách dần.
- **Tất định** (khác K-means).
- Không cần chọn K trước; cắt dendrogram ở độ cao $h \Rightarrow$ chọn số cụm.
- **Phức tạp** $O(n^2 \log n) \Rightarrow$ khó dùng cho n lớn.

Linkage

Loại	Khoảng cách giữa cụm	Tính chất
Single	min	chuỗi (chaining), cụm dài mảnh, nhạy nhiễu
Complete	max	cụm gọn, đường kính nhỏ
Average	trung bình	cân bằng
Centroid	giữa 2 centroid	có thể bị “đảo ngược”
Ward	tăng SSE khi gộp	cụm cầu, kích thước tương đương

Đọc dendrogram

Chiều cao = khoảng cách lúc gộp. **Thứ tự lá trên trục x không duy nhất** (có thể lật).

Khoảng cách & chuẩn hoá

- Euclid, Manhattan, **dựa trên tương quan** (phù hợp khi muốn so sánh hình dạng, ví dụ profile khách hàng).
- **Chuẩn hoá** trước phân cụm khi thang đo khác.
- Vector đếm từ → **không nên** dùng Euclid trực tiếp; ưu tiên cosine/correlation.

Mở rộng

Biclustering: phân cụm đồng thời hàng & cột (gene $\times$ sample).

Chương 9. Cây quyết định & Ensemble

Mục tiêu học

- Dựng cây thủ công bằng Gini / Entropy / RSS.
- Cắt tỉa theo α .
- So sánh Bagging / Random Forest / Boosting về cơ chế và bias-variance.

Cây quyết định

- **Phân chia nhị phân đệ quy** (greedy): chọn (j, s) cực tiểu hàm mất mát ngay tại bước hiện tại — không tối ưu toàn cục.
- **Cây hồi quy**: tiêu chí phép tách = giảm **RSS**; dự đoán = trung bình y trong lá.
- **Cây phân lớp**: dùng độ đo tạp chất:
 - **Gini**: $G = \sum_k \hat{p}_k(1 - \hat{p}_k) = 1 - \sum_k \hat{p}_k^2$.
 - **Entropy**: $H = - \sum_k \hat{p}_k \log_2 \hat{p}_k$.
 - **Classification error**: $1 - \max_k \hat{p}_k$ — ít nhạy $\Rightarrow$ ít dùng cho việc tách.
- **Information gain** = mức giảm tạp chất so với weighted children.
- Tạp chất = 0 $\Leftrightarrow$ nút thuần khiết.
- Cây **không cần chuẩn hoá đặc trưng**; xử lý hỗn hợp số/định tính tự nhiên.
- **Diễn giải** tốt nhưng **phương sai** cao, dễ overfit.

Cắt tỉa (cost-complexity pruning)

$$C_\alpha(T) = \sum_m \sum_{i \in R_m} (y_i - \hat{y}_{R_m})^2 + \alpha |T|.$$

- $\alpha = 0$: cây đầy. - α tăng $\Rightarrow$ cây nhỏ hơn. - Chọn α tối ưu bằng CV. - **Pre-pruning** (early stopping: max_depth, min_samples) vs **post-pruning**.

Bagging

- Bootstrap B tập, fit cây trên mỗi tập, trung bình/voting.

- **Giảm phương sai**, không thay đổi bias.
- **OOB error** = đánh giá miễn phí (không cần CV).

Random Forest

- Mỗi split chỉ xét m **đặc trưng ngẫu nhiên** trong $p \rightarrow$ **decorrelate** cây.
- Mặc định: phân lớp $m \approx \sqrt{p}$, hồi quy $m \approx p/3$.
- Cây ít tương quan $\Rightarrow$ giảm phương sai mạnh hơn bagging.

Boosting

- Xây dựng cây **tuần tự**, mỗi cây mới khớp residual của cây trước.
- 3 siêu tham số chính: số cây B , **độ co rút (shrinkage)** λ ($\approx 0.01-0.1$), **interaction depth** d .
 $d = 1 \Rightarrow$ mô hình cộng tính.
- Có thể overfit nếu B quá lớn $\Rightarrow$ chọn B bằng CV.

So sánh ensemble

	Bagging	Random Forest	Boosting
Cây độc lập?	Có	Có	Không (tuần tự)
Mục đích chính	Giảm variance	Giảm variance hơn nữa (decorrelate)	Giảm bias, có thể giảm variance
Đánh giá tự do	OOB	OOB	CV
Overfit khi B lớn?	Không	Không	Có thể

Tầm quan trọng biến

Mức giảm tạp chất tích lũy / permutation importance.

Biên quyết định nhanh

- Đường chéo $\rightarrow$ **mô hình tuyến tính**.
- Bậc thang/khối hộp song trục $\rightarrow$ **cây**.
- Đường thẳng đứng/ngang $\rightarrow$ cả tuyến tính và cây đều tốt.

Chương 10. Support Vector Machines

Mục tiêu học

- Dẫn dắt từ siêu phẳng $\rightarrow$ Phân lớp lề cực đại (MMC) $\rightarrow$ Soft-margin SVC $\rightarrow$ Kernel SVM.
- Chọn kernel + tham số C, γ, d phù hợp.
- So sánh SVM với LDA, logistic, k-NN.

Siêu phẳng tách

- **Siêu phẳng** trong $\mathbb{R}^p$: $\beta_0 + \beta^T x = 0$; β là vector pháp tuyến.
- Phân lớp theo dấu của $f(x) = \beta_0 + \beta^T x$, độ lớn $|f(x)|$ = mức độ tin cậy.
- Có **vô số** siêu phẳng tách khi tách được $\Rightarrow$ cần tiêu chí chọn.

Phân lớp lề cực đại (Maximal Margin Classifier, MMC)

$$\max_{\beta_0, \beta, M} M \quad \text{s.t.} \quad \|\beta\| = 1, y_i(\beta_0 + \beta^T x_i) \geq M.$$

- **Margin** = khoảng cách nhỏ nhất từ điểm tới siêu phẳng.
- **Vector hỗ trợ** = các điểm nằm chính xác trên lề; chỉ chúng ảnh hưởng siêu phẳng.
- **Hạn chế**: rất nhạy outlier; không dùng được khi 2 lớp overlap.

Support Vector Classifier — Soft margin

$$\max M \quad \text{s.t.} \quad y_i(\beta_0 + \beta^T x_i) \geq M(1 - \varepsilon_i), \varepsilon_i \geq 0, \sum \varepsilon_i \leq C.$$

- $\varepsilon_i = 0$: đúng phía lề.
- $0 < \varepsilon_i < 1$: vi phạm lề nhưng đúng phía siêu phẳng.
- $\varepsilon_i > 1$: phân lớp **sai**.
- Số sample bị phân lớp sai $\leq C$.

Quy ước về C :

- ISLR: C là **ngân sách vi phạm**, C lớn $\Rightarrow$ lề rộng, variance $\downarrow$ bias $\uparrow$.
- ESL/sklearn: C là penalty của slack, **ngược nghĩa** với ISLR.
- Cần đọc kỹ tài liệu nào trước khi diễn giải.

Chọn C bằng CV trên lưới log-scale.

Kernel trick

- Bài toán dual SVM chỉ phụ thuộc tích vô hướng $\langle x_i, x_j \rangle$.
- Thay $\langle x, x' \rangle \rightarrow K(x, x')$ — không cần map đặc trưng tường minh.
- **Kernel hợp lệ**: đối xứng + nửa xác định dương (Mercer).

Kernel phổ biến

Kernel	Công thức	Ghi chú
Tuyến tính	$\langle x, x' \rangle$	thử trước; tốt khi $p \gg n$
Đa thức	$(1 + \langle x, x' \rangle)^d$	tham số d
Gaussian RBF	$\exp(-\gamma \ x - x'\ ^2)$	γ lớn $\Rightarrow$ cục bộ hẹp $\Rightarrow$ overfit; γ rất nhỏ $\Rightarrow$ kernel $\approx$ hằng

Ánh xạ đặc trưng minh họa

Cho dữ liệu hình vòng lông, $Z = X_1^2 + X_2^2$ tách tuyến tính được.

Phân lớp đa lớp

- **OvO**: $\binom{K}{2}$ bộ + voting.
- **OvR**: K bộ + argmax.

Hinge loss

$$L = \max(0, 1 - yf(x)).$$

Bằng 0 khi $yf(x) \geq 1 \Rightarrow$ SVM “không quan tâm” điểm nằm xa siêu phẳng đúng phía.

So sánh

- **SVM vs LDA/Logistic:** SVM tập trung **vùng biên** (chỉ vector hỗ trợ); LDA dùng cả phân phối.
- **SVM $\approx$ Logistic** khi dữ liệu tách được tốt; phân kỳ khi có outlier.
- **Khi nào nên dùng SVM:** p vừa, biên phi tuyến rõ.
- **Khi nào tránh:** n rất lớn (tốn $O(n^2) - O(n^3)$); cần xác suất hậu nghiệm; cần diễn giải cao.

Chúc các bạn ôn tập hiệu quả!