

**Câu 1.** Một tập dữ liệu chứa một điểm ngoại lai nằm xa mọi điểm khác. Khi áp dụng kiểm định chéo chứa một mẫu (LOOCV) trên tập này, điểm ngoại lai ảnh hưởng đến sai số kiểm định chéo như thế nào?

- A. Điểm ngoại lai không ảnh hưởng vì chỉ làm validation đúng một trên  $n$  lần.  
B. Khi điểm ngoại lai vào fold huấn luyện, mô hình bị lệch nên đẩy sai số trung bình lên.  
C. Khi điểm ngoại lai vào fold kiểm định,  $K$ -fold bị ảnh hưởng hơn LOOCV do fold lớn hơn.  
D. **Khi điểm ngoại lai vào fold kiểm định, sai số trên nó rất lớn nên đẩy sai số trung bình lên.**

**Câu 2.** Bài toán phân lớp khác hồi quy ở điểm cốt lõi nào?

- A. Không cần dữ liệu huấn luyện có nhãn. B. Chỉ áp dụng được cho dữ liệu hình ảnh.  
C. Đầu ra là biến định lượng (continuous / liên tục). D. **Đầu ra là biến định tính (categorical / rời rạc).**

**Câu 3.** Một bộ phân lớp email cần phân vào một trong ba lớp loại trừ nhau: spam, khuyến mại (promo), cá nhân. Cấu hình hồi quy logistic phù hợp nhất?

- A. Hồi quy logistic đa thức với hàm sigmoid. B. Hồi quy tuyến tính đầu ra  $\{1, 2, 3\}$ .  
C. **Hồi quy logistic đa thức với hàm softmax.** D. Hồi quy logistic độc lập cho mỗi lớp.

**Câu 4.** Quy tắc một sai số chuẩn (one-standard-error rule, 1-SE) trong chọn  $\lambda$  qua kiểm định chéo (CV) hoạt động cụ thể như thế nào?

- A. Chọn  $\lambda$  lớn nhất mà sai số CV vẫn nằm trong 1 SE quanh CV-max.  
B. Chọn  $\lambda$  nhỏ nhất mà sai số CV vẫn nằm trong 1 SE quanh CV-min.  
C. **Chọn  $\lambda$  lớn nhất (đơn giản nhất) mà sai số CV vẫn nằm trong 1 SE quanh CV-min.**  
D. Chọn  $\lambda$  lớn nhất mà sai số CV vẫn nằm trong 1 SD quanh CV-min.

**Câu 5.** Bộ dữ liệu nào thường được coi là ví dụ kinh điển “Hello World” trong học sâu cho phân lớp ảnh?

- A. Titanic. B. Iris. C. ImageNet. D. **MNIST.**

**Câu 6.** Trong hồi quy logistic, khi  $\beta_1 = 0,7$ , nếu  $X$  tăng thêm 1 đơn vị thì tỉ lệ chênh (odds) thay đổi như thế nào?

- A. Log-odds nhân thêm 0,7 lần liên tiếp. B. Tỉ lệ chênh cộng trực tiếp thêm 0,7 đơn vị.  
C. **Tỉ lệ chênh nhân  $e^{0,7} \approx 2,01$  lần.** D. Xác suất nhân  $e^{0,7} \approx 2,01$  lần.

**Câu 7.** Vì sao spline tự nhiên bậc ba thường được ưu tiên hơn spline bậc ba thông thường?

- A. Tăng phương sai dự đoán ở hai biên miền dữ liệu so với spline bậc ba.  
B. Có số bậc tự do lớn hơn spline bậc ba nên luôn linh hoạt hơn khi khớp.  
C. Giảm phương sai dự đoán ở giữa miền dữ liệu so với spline bậc ba.  
D. **Giảm phương sai dự đoán ở hai biên miền dữ liệu so với spline bậc ba.**

**Câu 8.** Một ngân hàng triển khai hệ thống tầm soát gian lận thẻ tín dụng. Trong dữ liệu lịch sử, 99,3% giao dịch là hợp lệ và 0,7% là gian lận. Hệ thống đánh dấu giao dịch nghi vấn để nhân viên xác minh thủ công, với chi phí xác minh thấp nhưng chi phí bỏ sót gian lận rất cao. Cấu hình đánh giá phù hợp nhất?

- A. **Độ phủ (recall) ưu tiên + ngưỡng phân lớp thấp.**  
B. Độ chính xác (accuracy) với ngưỡng phân lớp mặc định.  
C. Hồi quy với đầu ra xác suất, không cần ngưỡng phân lớp.  
D. Độ chuẩn xác (precision) ưu tiên + ngưỡng phân lớp cao.

**Câu 9.** Tại một nút lá của cây phân lớp có hai lớp  $A, B$ , ước lượng tỉ lệ  $\hat{p}_A = 0,7$  và  $\hat{p}_B = 0,3$ . Lỗi phân lớp tại nút này có giá trị bằng bao nhiêu?

- A. **0,30.** B. 1,00. C. 0,50. D. 0,70.

**Câu 10.** Khi phân cụm văn bản, mỗi văn bản được biểu diễn bằng vector đếm số lần xuất hiện của các từ vựng. Vì sao khoảng cách Euclid KHÔNG phải là lựa chọn tốt để đo độ bất đồng giữa hai văn bản?

- A. Khoảng cách Euclid nhạy với phân phối dữ liệu — yêu cầu Gauss, không phù hợp vector đếm Poisson.
- B. Khoảng cách Euclid nhạy với thứ tự từ — văn bản đảo thứ tự cho khoảng cách lớn hơn.
- C. Khoảng cách Euclid nhạy với từ phổ biến (stop words) chiếm trọng số lớn trong vector đếm.
- D. **Khoảng cách Euclid nhạy với độ dài tổng thể của văn bản trong vector đếm từ.**

**Câu 11.** Khi thêm một điểm ngoại lai ở vùng biên phải của  $X$ , ảnh hưởng đến đường ước lượng sẽ khác nhau thế nào giữa hồi quy đa thức bậc cao và spline?

- A. **Đa thức bậc cao bị ảnh hưởng toàn miền  $X$ ; spline ít toàn cục, chủ yếu gần biên.**
- B. Cả hai đều bị ảnh hưởng cục bộ gần biên — điểm ngoại lai ở biên chỉ tác động vùng lân cận.
- C. Đa thức bậc cao bị ảnh hưởng toàn miền; spline cũng vậy nhưng mức độ lớn hơn do nhiều tham số.
- D. Spline bị ảnh hưởng toàn cục nhiều hơn đa thức vì có nhiều nút trên trục.

**Câu 12.** Khi sử dụng liên kết đơn (single linkage) cho phân cụm phân cấp trên dữ liệu có các điểm cầu nối (bridge points) giữa hai cụm tự nhiên, hiện tượng gì thường xảy ra?

- A. Thuật toán tạo ra các cụm có kích thước đều nhau bất kể có điểm cầu nối hay không.
- B. Hai cụm tự nhiên bị tách thành nhiều cụm nhỏ do điểm cầu nối tạo gián đoạn.
- C. Các điểm cầu nối hình thành cụm riêng tách biệt khỏi hai cụm tự nhiên.
- D. **Hiện tượng tạo chuỗi: hai cụm tự nhiên bị gộp lại do chuỗi các điểm gần nhau nối liền chúng.**

**Câu 13.** Khi huấn luyện Rừng ngẫu nhiên với  $B = 500$  cây trên dữ liệu  $n = 10.000$  mẫu, sai số ngoài bootstrap (OOB) có thể dùng thay cho kiểm định chéo (CV)  $K$ -fold khi nào?

- A. Khi  $B$  đủ lớn, OOB không chệch nhưng phương sai cao hơn  $K$ -fold.
- B. Khi  $n$  đủ lớn, OOB là ước lượng tin cậy của sai số kiểm thử.
- C. **Khi  $B$  đủ lớn, OOB là ước lượng tin cậy của sai số kiểm thử.**
- D. Khi  $n$  rất nhỏ ( $n < 100$ ), OOB tin cậy hơn  $K$ -fold.

**Câu 14.** Một mô hình hồi quy cho  $\hat{\beta}_1 = 3,2$  với  $SE(\hat{\beta}_1) = 0,8$ . Khoảng tin cậy 95% xấp xỉ cho  $\beta_1$  là bao nhiêu?

- A.  $[3,0; 3,4]$ .    B.  $[1,6; 4,8]$ .    C.  $[2,4; 4,0]$ .    D.  $[0,8; 5,6]$ .

**Câu 15.** Một đa thức từng mảnh bậc ba (piecewise cubic) với 2 nút (chưa có ràng buộc liên tục) có bao nhiêu tham số tự do?

- A. 10.    B. 8.    C. 12.    D. 6.

**Câu 16.** Một tập dữ liệu  $n = 200$  mẫu có nhãn nhiễu cao. Áp dụng Boosting với số cây lớn ( $B = 1.000$ ), nguy cơ chính là gì?

- A. Sai số huấn luyện tăng theo số cây, ngược chiều với mong đợi thông thường.
- B. Quá khớp — Boosting giảm trọng số mẫu nhiễu qua điều chỉnh trọng số thích nghi, rủi ro được giảm.
- C. Quá khớp — Boosting cần  $B$  lớn hơn nữa để các cây sau bù trừ dao động, nguy cơ giảm dần theo  $B$ .
- D. **Quá khớp — Boosting học cả nhiễu khi số cây nhiều, dữ liệu nhỏ và nhiễu.**

**Câu 17.** Một nghiên cứu phát hiện mối tương quan dương mạnh ( $r = 0,92$ ) giữa doanh số bán kem và số vụ đuối nước trong tháng. Kết luận nào là hợp lý nhất?

- A. **Có thể tồn tại biến ẩn (vd nhiệt độ) ảnh hưởng đồng thời đến cả hai biến quan sát được.**
- B. Tồn tại biến ẩn (nhiệt độ) làm tăng kem, kem (biến trung gian) sau đó làm tăng đuối nước.
- C. Tồn tại biến ẩn ảnh hưởng đuối nước nhưng không tới bán kem; tương quan  $r = 0,92$  là ngẫu nhiên.
- D. Hệ số tương quan  $r = 0,92$  chứng minh quan hệ nhân quả trực tiếp giữa hai biến.


**Câu 18.** Một nhà nghiên cứu có tập dữ liệu 1 triệu mẫu và muốn phân thành 5 cụm. Giữa K-means và phân cụm phân cấp tích tụ (Hierarchical Agglomerative Clustering, HAC), phương pháp nào phù hợp hơn và vì sao?

- A. HAC, vì không cần xác định trước  $K$ .
- B. **K-means, vì độ phức tạp thấp hơn nhiều so với HAC.**
- C. HAC, vì dendrogram trực quan hơn K-means.
- D. Cả hai tương đương trên dữ liệu lớn nếu phân cứng đủ mạnh.

**Câu 19.** Công thức của kernel đa thức bậc  $d$  là gì?

- A.  $K(x, x') = e^{-d \cdot \langle x, x' \rangle}$ .    B.  $K(x, x') = \langle x, x' \rangle^{1/d}$ .    C.  $K(x, x') = (1 + \langle x, x' \rangle)^d$ .    D.  $K(x, x') = \|x - x'\|^d$ .

**Câu 20.** Quan sát đường cong học tập (learning curve) dưới đây của một mô hình.



Mô hình đang gặp vấn đề gì?

- A. Đang rò rỉ dữ liệu.    B. Đang quá khớp.  
C. **Đang dưới khớp.**    D. Đã hội tụ tốt.

**Câu 21.** Một phòng khám sàng lọc ung thư hiếm: tỉ lệ bệnh trong dân số 0,5%. Mô hình đầu ra xác suất bệnh. Yêu cầu: bỏ sót ca bệnh càng ít càng tốt, ca dương tính giả vẫn chấp nhận được vì có bước xét nghiệm xác minh sau. Cách chọn ngưỡng và độ đo phù hợp?

- A. **Ngưỡng  $< 0,5$ , tối ưu độ phủ/độ nhạy (recall/sensitivity).**  
B. Ngưỡng 0,5 mặc định, tối ưu độ chính xác (accuracy).  
C. Ngưỡng  $> 0,5$ , tối ưu độ chuẩn xác (precision).  
D. Ngưỡng  $< 0,5$ , tối ưu điểm  $F_1$  (cân bằng độ chuẩn xác và độ phủ).

**Câu 22.** So sánh kiểm định chéo chứa một mẫu (LOOCV) với 10-Fold CV, phát biểu nào sau đây là đúng?

- A. LOOCV có cả độ chệch và phương sai đều thấp hơn 10-Fold CV.  
B. LOOCV có cả độ chệch và phương sai đều cao hơn 10-Fold CV.  
C. LOOCV có độ chệch cao hơn nhưng phương sai thấp hơn 10-Fold CV.  
D. **LOOCV có độ chệch thấp hơn nhưng phương sai cao hơn 10-Fold CV.**

**Câu 23.** Cho hai cụm  $A = \{(0, 0), (1, 0)\}$  và  $B = \{(3, 0), (5, 0)\}$  với khoảng cách Euclid. Khoảng cách giữa  $A$  và  $B$  theo liên kết đơn (single linkage) là bao nhiêu?

- A. 5,0.    B. **2,0.**    C. 3,5.    D. 4,0.

**Câu 24.** Phương pháp lựa chọn tập con tốt nhất trong hồi quy có nhược điểm lớn nhất là gì?

- A. Chỉ hoạt động khi số biến  $p$  nhỏ hơn số quan sát  $n$ .  
B. Cần chuẩn hóa tất cả biến đầu vào về Z-score trước khi chạy.  
C. Không bao giờ tìm được tập con tối ưu trong không gian đã xét.  
D. **Số mô hình phải khớp tăng theo cấp mũ ( $2^p$ ) khi có  $p$  biến.**


**Câu 25.** Phân tích thành phần chính (PCA) trên dữ liệu 5 chiều cho các trị riêng  $\lambda_1 = 3,0$ ,  $\lambda_2 = 1,5$ ,  $\lambda_3 = 0,3$ ,  $\lambda_4 = 0,1$ ,  $\lambda_5 = 0,1$ . Để tỷ lệ phương sai được giải thích (PVE) tích lũy đạt ít nhất 90%, cần giữ tối thiểu bao nhiêu thành phần chính?

- A. **Hai thành phần.**    B. Bốn thành phần.    C. Ba thành phần.    D. Một thành phần.

**Câu 26.** Cho hai cụm  $A = \{(0, 0), (2, 0)\}$  và  $B = \{(5, 0), (7, 0)\}$ . Khoảng cách giữa  $A$  và  $B$  theo liên kết đầy đủ (complete linkage) là bao nhiêu?

- A. 7.    B. 5.    C. 2.    D. 3.

**Câu 27.** Hình dưới đây mô tả việc huấn luyện bộ phân lớp vector hỗ trợ (SVC) trên cùng tập dữ liệu với ngân sách  $C$  giảm dần từ hình (a) đến hình (d) (theo quy ước trong sách ISLR — An Introduction to Statistical Learning). Tại sao mô hình ở hình (d) có rủi ro tổng quát hoá kém hơn mô hình ở hình (a)?



- A. Lệ hẹp tăng thiên lệch của mô hình.      B. Hình (d) có nhiều vector hỗ trợ nhất.  
 C. **Lệ hẹp khiến mô hình bám sát từng điểm.**      D. Số điểm vi phạm lề ở hình (d) lớn nhất.

**Câu 28.** Trong Phân tích thành phần chính (PCA), các vector riêng của ma trận hiệp phương sai đại diện cho điều gì?

- A. Tỷ lệ phương sai tích lũy được giải thích bởi các thành phần.  
 B. Các hướng trong không gian giảm chiều sau khi áp dụng PCA.  
 C. Độ lớn phương sai mà từng thành phần chính giải thích được.  
 D. **Các hướng trong không gian gốc của các thành phần chính.**

**Câu 29.** Một hệ thống gợi ý phim học từ lịch sử xem và đánh giá của người dùng để đề xuất phim mới. Thành phần Kinh nghiệm (Experience  $E$ ) trong khung T-P-E là gì?

- A. Thuật toán lọc cộng tác dùng trong hệ thống gợi ý.  
 B. **Lịch sử xem phim và điểm đánh giá đã có của người dùng.**  
 C. Đề xuất danh sách phim phù hợp cho người dùng đang đăng nhập.  
 D. Mức độ hài lòng của người dùng đo qua tỉ lệ click vào phim.


**Câu 30.** Khi chỉ số tạp chất Gini của một nhánh rất thấp (gần 0), điều đó có ý nghĩa gì?

- A. **Nhánh đó có lớp gần như thuần khiết.**      B. Nhánh đó không thể chia tiếp nữa.  
 C. Nhánh đó có phân bố lớp rất hỗn loạn.      D. Nhánh đó có hai lớp cân bằng tuyệt đối.

**Câu 31.** Cho các biến: (1) Màu sắc sản phẩm (đỏ, xanh, vàng), (2) Mức độ hài lòng (rất không hài lòng  $\rightarrow$  rất hài lòng), (3) Giới tính (nam, nữ). Biến nào thuộc loại thứ tự?

- A. Cả ba biến đều là thứ tự vì có hữu hạn giá trị có thể đếm.  
 B. Chỉ biến (3) là thứ tự vì nam/nữ có thể mã hóa 0 và 1 có thứ tự.  
 C. **Chỉ biến (2) là thứ tự vì các giá trị có thứ tự rõ ràng.**  
 D. Chỉ biến (1) là thứ tự vì màu sắc có thể sắp theo bước sóng phổ ánh sáng.

**Câu 32.** Hình dưới cho thấy đường cong ROC của ba bộ phân lớp  $M_1, M_2, M_3$  và đường tham chiếu Ngẫu nhiên.



Mô hình nào có AUC cao nhất và (gần như) ưu trội hơn hai mô hình còn lại ở mọi giá trị FPR?

- A.  $M_2$  — đường nét đứt ở giữa.      B. Cả ba mô hình tương đương.  
C.  $M_1$  — **đường liền nét trên cùng.**      D.  $M_3$  — đường chấm dưới cùng.

**Câu 33.** Để biểu diễn spline bậc ba thông thường với  $K$  nút bằng hàm cơ sở lũy thừa cắt cụt (truncated power basis), cần bao nhiêu hàm cơ sở (kể cả phần đa thức)?

- A.  $K + 4$ .      B.  $K$ .      C.  $3K + 1$ .      D.  $K + 3$ .

**Câu 34.** Cho dữ liệu hồi quy 1 chiều gồm 6 điểm  $(x_i, y_i)$ :

|       |   |   |   |   |    |    |
|-------|---|---|---|---|----|----|
| $x_i$ | 1 | 2 | 3 | 4 | 5  | 6  |
| $y_i$ | 1 | 2 | 8 | 9 | 10 | 11 |

Trong các ngưỡng phân chia  $s$  sau (tách thành nhánh  $X < s$  và  $X \geq s$ , mỗi nhánh dự đoán bằng trung bình  $y$  của nhánh đó), ngưỡng nào cho tổng bình phương sai số (RSS) nhỏ nhất?

- A.  $s = 3,5$ .      B.  $s = 2,5$ .      C.  $s = 1,5$ .      D.  $s = 4,5$ .

**Câu 35.** Trong bảng kết quả hồi quy tuyến tính bội của bộ dữ liệu Advertising (kênh quảng cáo TV, Radio); mô hình  $Y = \beta_0 + \beta_1 \text{TV} + \beta_2 \text{radio} + \beta_3 (\text{TV} \cdot \text{radio}) + \varepsilon$ :

| Thành phần        | Hệ số $\hat{\beta}$ | Sai số chuẩn | $t$ -statistic | $p$ -value |
|-------------------|---------------------|--------------|----------------|------------|
| Chặn              | 6,7502              | 0,248        | 27,23          | < 0,0001   |
| TV                | 0,0191              | 0,002        | 12,70          | < 0,0001   |
| radio             | 0,0289              | 0,009        | 3,24           | 0,0014     |
| TV $\times$ radio | 0,0011              | 0,000        | 20,73          | < 0,0001   |

Hệ số  $\hat{\beta}_3 = 0,0011$  của biến tương tác ‘TV  $\times$  radio’ cho biết điều gì?

- A. Mức tăng cố định của Sales khi cả TV và radio cùng tăng 1 đơn vị.  
B. Khi radio tăng 1, hệ số cận biên của TV giảm 0,0011.  
C. Khi radio = 0, hệ số cận biên của TV là 0,0011.  
D. **Khi radio tăng 1, hệ số cận biên của TV tăng thêm 0,0011.**

**Câu 36.** Khi mở rộng máy vector hỗ trợ (SVM) sang phân lớp đa lớp bằng chiến lược một-đối-một (One-vs-One, OvO) cho  $K = 5$  lớp, cần huấn luyện bao nhiêu bộ phân lớp nhị phân?

- A. 120.      B. 32.      C. 5.      D. 10.

**Câu 37.** Trong Bagging, lỗi quan sát ngoài bootstrap (OOB) được tính bằng cách nào?

- A. Dự đoán mỗi quan sát bằng các cây có chứa quan sát đó trong mẫu bootstrap.  
B. Dự đoán mỗi quan sát bằng toàn bộ cây trong rừng, không phân biệt mẫu bootstrap.  
C. **Dự đoán mỗi quan sát chỉ bằng các cây không chứa quan sát đó trong mẫu bootstrap.**  
D. Chia dữ liệu thành  $K$  phần bằng nhau rồi thực hiện kiểm định chéo (CV)  $K$ -fold.

**Câu 38.** Khi chọn ngân sách  $C$  cho bộ phân lớp vector hỗ trợ với lẽ mềm bằng kiểm định chéo (CV), cách làm khuyến nghị là gì?

- A. Quét  $C$  trên lưới đều tuyến tính, chọn  $C$  có lỗi CV nhỏ nhất.
- B. Quét  $C$  trên lưới log-scale, chọn  $C$  có lỗi huấn luyện nhỏ nhất.
- C. Quét  $C$  trên lưới log-scale, chọn  $C$  có ít vector hỗ trợ nhất.
- D. Quét  $C$  trên lưới log-scale, chọn  $C$  có lỗi CV nhỏ nhất.

**Câu 39.** Hàm logistic  $p(X) = e^z / (1 + e^z)$  có miền giá trị thuộc khoảng nào?

- A.  $[0, 1]$ .
- B.  $(0, 1)$ .
- C.  $(-\infty, +\infty)$ .
- D.  $(-1, 1)$ .

**Câu 40.** Trong hồi quy Ridge với tham số phạt  $\lambda$ , bậc tự do hiệu dụng  $df(\lambda)$  đo độ phức tạp thực sự của mô hình. Khi  $\lambda$  tăng từ 0 đến vô cùng,  $df(\lambda)$  thay đổi thế nào?

- A. Giảm dần và tiến về 0 khi  $\lambda \rightarrow \infty$ .
- B. Tăng dần và tiến về  $p$  khi  $\lambda \rightarrow \infty$ .
- C. Không đổi, luôn bằng  $p$  với mọi  $\lambda$ .
- D. Dao động không theo quy luật xác định.

**Câu 41.** Cho ma trận nhầm lẫn của một mô hình phân lớp nhị phân:

|                    | Dự đoán Dương tính | Dự đoán Âm tính |
|--------------------|--------------------|-----------------|
| Thực tế Dương tính | 40                 | 10              |
| Thực tế Âm tính    | 20                 | 30              |

Độ chuẩn xác (precision) của mô hình bằng bao nhiêu?

- A.  $40/50 = 0,80$
- B.  $30/50 = 0,60$
- C.  $70/100 = 0,70$
- D.  $40/60 \approx 0,67$

**Câu 42.** Một biến phân loại 'Khu vực' có 4 giá trị: Bắc, Trung, Nam, Tây. Khi đưa vào mô hình hồi quy có hệ số chặn, cần tạo bao nhiêu biến giả để tránh bẫy biến giả?

- A. 4 biến giả.
- B. 3 biến giả.
- C. 1 biến giả.
- D. 2 biến giả.

**Câu 43.** Một nhà phân tích dùng mô hình cộng tính tổng quát (GAM) dự đoán giá nhà theo diện tích ( $X_1$ ) và khoảng cách đến trung tâm ( $X_2$ ). GAM chuẩn có hạn chế gì khi ảnh hưởng của diện tích phụ thuộc vào vị trí?

- A. GAM không tự động mô hình hoá tương tác giữa các biến đầu vào.
- B. GAM chỉ dùng được duy nhất một loại làm mượt chung cho mọi biến.
- C. GAM không thể xử lý các biến đầu vào liên tục như diện tích nhà.
- D. GAM yêu cầu cỡ mẫu rất lớn (trên 10 000 quan sát) mới khớp được.

**Câu 44.** Trong bài toán phân lớp khả năng mất khách hàng, với  $n = 50.000$ ,  $p = 200$  biến đầu vào. Mục tiêu: vừa dự đoán tốt vừa biết biến nào quan trọng nhất. Phương pháp nào phù hợp?

- A. Cây quyết định đơn.
- B. Rừng ngẫu nhiên.
- C. Hồi quy tuyến tính.
- D.  $k$  láng giềng gần nhất.

**Câu 45.** Cho bài toán phân lớp nhị phân ( $Y = 0$  và  $Y = 1$ ) với 1 đặc trưng  $X$  có 2 giá trị. Biết  $P(Y = 1) = 0,4$ ,  $P(Y = 0) = 0,6$ ,  $P(X = a | Y = 1) = 0,8$ ,  $P(X = a | Y = 0) = 0,3$ . Naïve Bayes phân lớp quan sát  $X = a$  vào lớp nào?

- A. Lớp  $Y = 1$  vì  $0,8 \times 0,4 = 0,32 > 0,3 \times 0,6 = 0,18$ .
- B. Lớp  $Y = 0$  vì  $P(Y = 0)$  lớn hơn  $P(Y = 1)$  về xác suất tiên nghiệm.
- C. Lớp  $Y = 0$  vì  $P(X = a | Y = 0) \cdot P(Y = 0) > P(X = a | Y = 1) \cdot P(Y = 1)$ .
- D. Lớp  $Y = 1$  vì  $P(X = a | Y = 1) = 0,8$  là hợp lý lớn nhất.

**Câu 46.** Mô hình dự đoán giá bất động sản có 3 biến đầu vào: diện tích sàn, số phòng ngủ và số phòng tắm. Thống kê cho thấy hệ số tương quan giữa các biến đều  $> 0,9$ . Vấn đề gặp phải và cách xử lý phù hợp là gì?

- A. Đa cộng tuyến — hệ số bất ổn; xử lý bằng biến đổi log hoặc sqrt cho mỗi biến đầu vào.
- B. Đa cộng tuyến — hệ số bất ổn; xử lý bằng chuẩn hoá min-max về  $[0, 1]$  cho mỗi biến đầu vào.
- C. Đa cộng tuyến — hệ số bất ổn; xử lý bằng tăng kích thước mẫu  $n$  để giảm phương sai hệ số.
- D. Đa cộng tuyến — hệ số bất ổn; xử lý bằng Ridge hoặc bỏ bớt biến tương quan.

**Câu 47.** Phát biểu nào đúng về số cây  $B$  trong Boosting so với Bagging?

- A. Số cây  $B$  không ảnh hưởng đến hiệu suất của cả hai phương pháp.
- B. Boosting có thể quá khớp khi  $B$  lớn còn Bagging ít bị.**
- C. Cả hai đều không bao giờ quá khớp khi  $B$  tăng.
- D. Bagging có thể quá khớp khi  $B$  lớn nhưng Boosting thì không.

**Câu 48.** Khi áp dụng Phân tích thành phần chính (PCA), ma trận nào được phân rã trị riêng?

- A. Ma trận hiệp phương sai giữa các quan sát.
- B. Ma trận khoảng cách Euclid giữa mọi cặp điểm dữ liệu.
- C. Ma trận nhân one-hot biểu diễn các lớp đầu ra.
- D. Ma trận hiệp phương sai/tương quan giữa các đặc trưng.**

**Câu 49.** Khi dùng kiểm định chéo (CV) 5-Fold để chọn siêu tham số  $\lambda$  cho hồi quy ridge với bốn giá trị ứng viên  $\lambda \in \{0,01; 0,1; 1; 10\}$ , tổng cộng cần huấn luyện bao nhiêu mô hình?

- A. 20.**
- B. 5.
- C. 9.
- D. 4.

**Câu 50.** Một hệ thống nhận dạng chữ viết tay được huấn luyện trên bộ dữ liệu chữ số viết tay (MNIST). Trong khung T-P-E, thành phần Độ đo hiệu suất (Performance measure  $P$ ) phù hợp nhất là gì?

- A. Nhận dạng ký tự từ ảnh chữ số viết tay đầu vào ( $28 \times 28$ ).
- B. Tỷ lệ phần trăm ký tự được nhận dạng đúng trên tập kiểm thử.**
- C. Thời gian huấn luyện trên đơn vị xử lý đồ họa (GPU) đo bằng giây.
- D. Tập 60 000 ảnh chữ số viết tay đã gán nhãn (MNIST train).